

DOI: 10.16513/j.2096-2185.DE.2106621

基于小波变换的改进混合蛙跳-差分进化-神经网络预测模型的短期风速预测

付晓敏

(中国大唐集团科学技术研究院有限公司西北电力试验研究院, 陕西省 西安市 710000)

摘要: 针对目前对风速序列短期预测中不同组合算法预测精度较差、适应性不强等问题, 提出一种基于小波变换的组合预测模型算法, 将风速序列经小波变换降低波动性与无序性, 利用混合蛙跳算法 (shuffled frog leaping algorithm, SFLA) 优化逆向传播 (back propagation, BP) 神经网络的初始权值与阈值, 将差分进化 (difference evolution, DE) 算法用于混合蛙跳算法子种群个体寻优策略, 提高个体收敛速度与精度。通过将经小波变换分解得到的高、低频分量分别经组合模型算法进行风速预测与重构, 通过实例验证, 10、30 min 相较 60 min 预测结果平均绝对百分比误差分别提高 33.59%、12.21%, 均方根误差分别提高 28.77%、8.22%, 三者平均预测误差分别为 0.037、-0.014、0.011 m/s, 与混合蛙跳-BP 神经网络算法、BP 神经网络算法横向对比, 结果表明所提组合预测模型算法预测性能指标最佳。

关键词: 风速; 预测; 小波变换; 混合蛙跳算法 (SFLA); 差分进化 (DE) 算法; 组合预测模型

中图分类号: TK 89

文献标志码: A

Short-Term Wind Speed Prediction Based on Improved Wavelet Transform and Shuffled Frog Leaping Difference Evolution Neural Network Algorithm

FU Xiaomin

(Northwest Electric Power Research Institute, China Datang Corporation Science and Technology Research Institute Ltd., Xi'an 710000, Shaanxi Province, China)

ABSTRACT: Aiming at the problems of poor prediction accuracy and poor adaptability of different combination algorithms in the current short-term forecasting of wind speed series, this paper proposes a combination forecasting model based on wavelet transform, which reduces the volatility and disorder of wind speed series through wavelet transform. The shuffled frog leaping algorithm (SFLA) is used to optimize the initial weight and threshold of the back propagation (BP) neural network, and the difference evolution (DE) algorithm is used in the SFLA's subpopulation individual optimization strategy which improves the speed and accuracy of individual convergence. The high and low frequency components decomposed by the wavelet transform are respectively used for wind speed prediction and reconstruction through the combined model algorithm. Compared with the 60 min prediction results, the mean absolute percentage errors of 10 min and 30 min were increased by 33.59% and 12.21% respectively, and the root mean square errors were increased by 28.77% and 8.22% respectively. The average prediction errors of the three are 0.037, -0.014, 0.011 m/s, horizontally compared with the SFLA-BP neural network algorithm and the BP neural network algorithm, the results show that the combination forecasting model of this paper predicts the best performance indicators.

KEY WORDS: wind speed; forecast; wavelet transform; shuffled frog leaping algorithm (SFLA); difference evolution (DE) algorithm; combination forecasting model

基金项目: 中国大唐集团科学技术研究院西北院科技项目 (XB2020-03)

Project supported by Science and Technology Projects of Northwest Electric Power Research Institute of China Datang Corporation Science and Technology Research Institute (XB2020-03)

0 引言

随着全球对碳减排达成的共识以及我国“30·60”双碳目标的提出, 清洁电力对促进减碳的意义得到显著提升, 截止 2021 年三季度末, 我国累计并网风

电装机达到 3.0 亿 kW, 风电利用率 98.3%^[1], 大规模风电的并网对电网结构稳定性提出更高要求, 适应新能源高渗透率的新型电力系统成为未来能源革命的重要方向。风力发电受制于风速的波动性, 易对电网的平衡保障与结构稳定造成负面影响^[2-5], 多时间分辨率下风速的准确预测, 对于电网出力调度与负荷消纳平衡具有关键的作用^[6]。

风速预测的主要方向分为机理驱动法与模型驱动法^[7], 其中模型驱动法由于方法多样与预测精度较高, 得到了广泛的应用。组合预测方法融合信号分解、机器学习与深度学习算法, 相较单一的预测模型, 降低了历史风速序列数据特征与深度信息提取难度, 简化了预测模型搭建的结构复杂度。文献[8]利用经验模态分解处理风速序列, 输入到最小二乘向量机得到短期预测模型; 文献[9]将小波分解应用于风功率数据高、低频分解, 后利用遗传算法优化逆向传播(back propagation, BP)神经网络初始值。文献[10]利用变分模态分解与模拟信息粒化将原始风速序列分解为趋势、振荡和噪声 3 部分, 对各子序列建立粒子群算法寻优的门控循环单元预测模型。

混合蛙跳算法(shuffled frog leaping algorithm, SFLA)是一种基于群体智能的后启发式算法^[11], 算法将问题的寻优过程模拟为青蛙群体分散觅食, 周期性重聚分享食物来源信息的过程, 具有参数设置少、操作简单、寻优性能强等特点, 已应用于水资源调度、生产调度与车辆路线规划等多个领域^[12-14]。SFLA 在快速并行搜索与寻优过程中易陷入局部最小值, 在演化后期收敛较慢, 本文基于已有研究成果, 利用小波变换进行风速序列的时-域分解, 降低预测难度, 将差分进化算法(differential evolution, DE)^[15]引入 SFLA 中, 改进子种群寻优策略, 发挥其结构简单、鲁棒性强等优点, 将 SFLA 的全局寻优能力与 DE 的快速收敛结合, 使得新算法具有较优的收敛速度与精度。

1 小波变换

小波变换来源于傅里叶分析, 是一种通过伸缩与平移对信号进行多分辨率时-频窗分析的工具, 1988 年 SMallat 在多尺度逼近的理论基础上提出多分辨率分析理论^[16], 提出的快速塔式小波分解算法与重构算法, 可以快速将信号分解为带有子特征的若干时域分量之和, 通过改变平移参数与尺度参数, 可以分析任意局部时-域窗的信号, 克服了傅里叶变换的固有缺点。

采用小波变换分解风速时间序列, 可以有效降低风速的波动性与无序性, 降低风速预测的不确定性, 其实质是将原始信号 $f(t)$ 从 $j+1$ 多重尺度到降尺度逐步分解的过程, 即对信号从高分辨率到低分辨率的分解过程, 为 $D_{j-1}, D_{j-2}, \dots, D_0, A_0$, 计算公式为:

$$A_{j,n} = \frac{\sqrt{2}}{2} \sum_{k \in Z} A_{j+1,k} h_{k-2n} \quad (1)$$

$$D_{j,n} = \frac{\sqrt{2}}{2} \sum_{k \in Z} A_{j+1,k} g_{k-2n} \quad (2)$$

式中: h_{k-2n} 与 g_{k-2n} 分别为正交小波的传递系数, 分别为低通、高通数字滤波器; $A_{j,n}$ 表示近似信号, 可反映该序列的整体变化趋势; $D_{j,n}$ 表示细节信号, 可反映蕴含在原始序列中不同频域的随机扰动; j 为尺度参数, k 为平移参数。

小波重构算法是小波分解算法的逆过程, 在将各频率序列分量进行预测拟合后按照式(3)进行重构。

$$A_{j,n} = \frac{\sqrt{2}}{2} \sum_k A_{j+1,k} h_{n-2k} + \sum_k D_{j+1,k} g_{n-2k} \quad (3)$$

2 改进 SFLA-DE 算法

2.1 SFLA

SFLA 将问题的寻优过程模拟为青蛙群体分散觅食, 食物的存在范围相当于问题中解的搜索空间, 青蛙个体表征问题的一个可能解, 种群个体分解为多个子种群外出觅食, 寻求最优食物路径, 周期性的聚集通过分享食物来源信息指引所有蛙群个体趋于食物位置, 其高效性来源于子种群内寻优与子种群周期性混合 2 个关键部分, 二者平衡算法的局部搜索与全局寻优。

设定蛙群由 G 只青蛙个体组成, 在 E 维解空间中, 每一只青蛙个体代表问题的一个解, 表示为 $X_i = (x_{i1}, x_{i2}, \dots, x_{iE})$, $i \in G$ 。首先计算所有个体适应度值, 按照升序或者降序统一排序; 其次, 进行子种群个体分配任务, 将第一只青蛙分配到第一个子种群中, 第二个青蛙分配到第二个子种群中, 以此类推, 将所有个体划分至 N 个子种群中, 子种群中个体数为 M , 满足 $G = NM$, 形成子种群序列 $Y = \{Y_1, Y_2, \dots, Y_N\}$; 进行各子种群内部局部搜索更新, 更新机制为:

$$d_i = r(X_y^b - X_y^w), \quad d_i \in [d_{\max}, d_{\min}] \quad (4)$$

$$X'_y = X_y^w + d_i \quad (5)$$

式中: X_y^b 、 X_y^w 分别表示子种群 y 中最优个体与最差个体; r 为 $[0, 1]$ 之间的随机数; d_i 表示最差个体

的更新步长; X'_y 表示 X_y^w 经过更新后的解。

若更新解 X'_y 优于 X_y^w , 则替换子种群内最差个体, 进行下一次局部搜索, 否则将 X_y^w 替换为蛙群 G 中的最优解 X_k^G , 重新利用式(4)和式(5)执行更新策略; 如若仍未产生优于 X_y^w 的更新解, 则随机产生一个新的个体, 重复执行上述更新策略, 直到达到子种群迭代次数 S , 将所有个体重新混合, 计算适应度值, 划分子种群重新搜索, 直到满足全局迭代次数或者其他条件后结束。以上算法实现过程如图1所示。

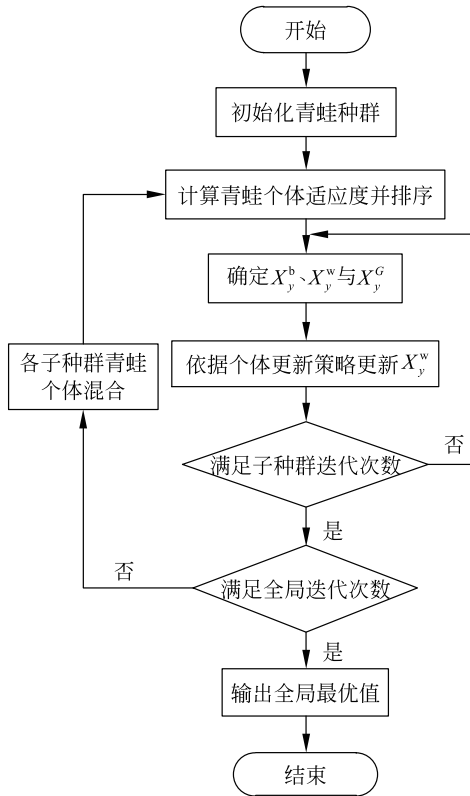


图1 SFLA流程图

Fig. 1 Flowchart of the SFLA

2.2 基于DE算法的个体自适应寻优策略

DE算法的核心思想是首先由若干个父代个体间的差分向量产生新的变异个体, 然后按照一定的交叉概率, 将目标个体与变异个体交换部分元素杂交得到试验个体, 后根据竞争策略选择适应度较优的个体进入到下一代群体。DE算法的基本操作包括变异、交叉和选择3种操作。

1) 变异操作。

对每个目标个体, 按照个体向量加权差跳变的策略产生变异个体, 公式为

$$V(t) = X_{i_1}(t) + F[X_{i_2}(t) - X_{i_3}(t)] \quad (6)$$

式中: $X_{i_1}(t)$, $X_{i_2}(t)$, $X_{i_3}(t)$ 为在子种群第 t 次迭代中随机选择的3个个体, $i_1 \neq i_2 \neq i_3$; F 为差分矢量缩放因子。

对式(6)提出改进措施, 提高局部搜索效率, 公式为:

$$V_i(t) = X^b(t) + F[X_{i_1}(t) - X_{i_2}(t)] \quad (7)$$

式中: $X^b(t)$ 为子种群中最优个体。

式(7)中 F 为介于 $[0, 2]$ 的实数型常量因子, 当取值 F 较大时, 生成的变异个体与当前个体差异较大, 有助于保持种群的多样性和跳出局部最优, 加快全局收敛; 当 F 取值较小时, 生成的变异个体与当前个体差异较小, 围绕最优解精细化搜索, 有利于局部搜索和加速收敛。基于 F 的这一特性, 设计 F 动态变化策略, 使得 F 随着 SFLA 全局迭代次数的逐渐增加而逐渐减小, 公式为

$$F_i = F_{\max} - \frac{i(F_{\max} - F_{\min})}{Q}, \quad i = 1, 2, \dots, Q \quad (8)$$

式中: $F \in [F_{\min}, F_{\max}]$; Q 为 SFLA 全局迭代次数。

2) 交叉操作。

将目标个体与变异个体按照一定概率交换向量元素的方式产生试验个体, 以此增加种群个体的多样性, 本文采用二项式交叉方法交差不同位置元素, 生产试验个体 $U_i = \{u_{i1}, u_{i2}, \dots, u_{iD}\}$, 公式为:

$$u_{ij} = \begin{cases} v_{ij}(t), & \text{if } r_1 \leq C \text{ or } j = r_2 \\ x_{ij}(t), & \text{if } r_1 > C \text{ or } j \neq r_2 \end{cases} \quad (9)$$

式中: $C \in [0, 1]$, 为杂交概率, 控制变异个体和目标个体对试验个体的影响程度; r_1 为 $[0, 1]$ 之间的随机数; r_2 为 $[1, D]$ 之间的随机整数, $j = r_2$ 保证 u_{ij} 中至少从变异个体中继承一个元素, 确保试验个体与变异个体的差异性。

当 C 取值较大时, 交叉个体与变异个体差异较大, 有助于算法未知空间的拓展; 当 C 取值较小时, 交叉个体与变异个体差异较小, 当算法迭代后期时, 较小的 C 利于保证具有良好向量因子的个体免遭过多的破坏, 加快算法收敛。改进策略为:

$$C_i = C_{\max} - \frac{i(C_{\max} - C_{\min})}{Q} \quad (10)$$

式中: $C_i \in [C_{\max}, C_{\min}]$ 。

3) 选择操作。

DE的选择操作是基于适者生存的贪婪选择机制, 针对特定的2个目标函数的多目标问题, 参数 L 为设定最大循环次数, DE选择操作机流程如图2所示。

3 短期风速预测模型

本文基于改进 SFLA-DE 进行神经网络初始权

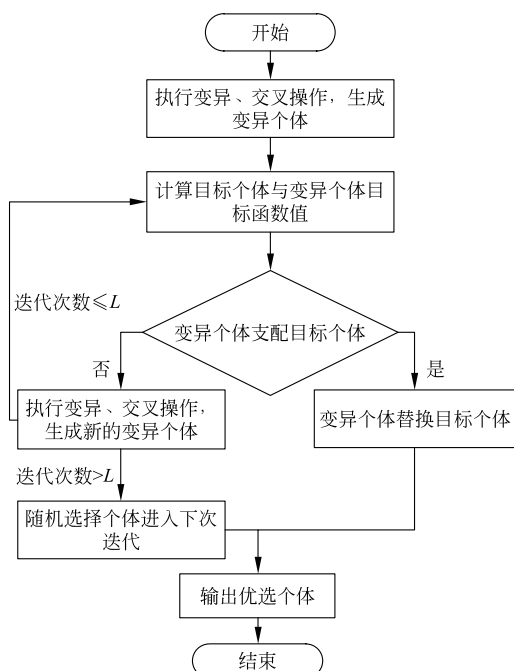


图2 DE算法选择操作流程

Fig. 2 Flowchart of DE algorithm selection operation

值与阈值寻优,输出最优BP神经网络权值与阈值个体元素,并赋值于BP神经网络,提出混合蛙跳差

分进化-BP神经网络预测(SFLA-DE-BP)模型,将其应用于短期风速数据的预测中。基本步骤如下:

S1 获取一定时段的风速数据,利用小波变换进行多层时-域分解。

S2 基于改进差分混合蛙跳-神经网络算法建立测风数据预测模型,将经小波变换得到的高、低频分量 $D_{j-1}, D_{j-2}, \dots, D_0, A_0$ 分为训练样本与测试样本,将训练样本用于所建模型训练,得到BP神经网络优化权值与阈值。

S3 利用测试样本检验模型预测效果,经小波重构后与实测值进行对比分析。

S3.1 以低频分量 A_0 为例,经模型进行神经网络初始权值与阈值寻优计算,完成模型构建,输入数据经运算后得到输出样本数据。

S3.2 以此类推,分别完成剩余高频分量 $D_{j-1}, D_{j-2}, \dots, D_0$ 的输入与预测数据输出。

S3.3 将预测得到的各高频分量与低频分量经小波重构成风速数据,与同期实测风速数据进行对比分析,计算并评价拟合效果,流程如图3所示。

采用平均绝对百分比误差 ϵ_{MAPE} 、均方根误差

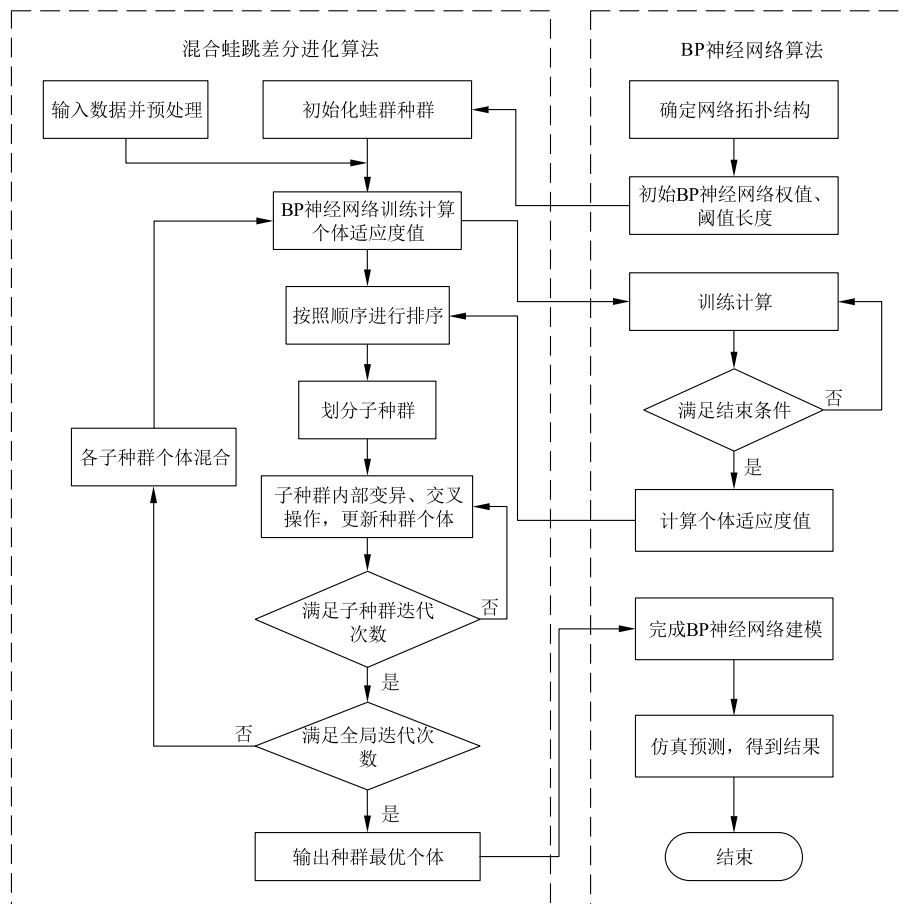


图3 改进混合蛙跳-差分进化-BP神经网络算法流程图

Fig. 3 Flowchart of improved SFLA-DE-BP algorithm

ϵ_{RMSE} 指标进行计算,公式如下:

$$\epsilon_{\text{MAPE}} = \frac{1}{N} \sum_{i=1}^N \frac{|v_i - v_i^*|}{v_i} \times 100\% \quad (11)$$

$$\epsilon_{\text{RMSE}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (v_i - v_i^*)^2} \quad (12)$$

4 案例分析

4.1 风速序列

获取某风电场测风塔 2019-06-27T00:00 至 2019-06-27T23:50 在 90 m 高度处实测风速数据,采样频率为 10 min,数据点共 380 个,划分前 350 个数据点为训练样本,剩余 30 个数据点为拟合样本。

4.2 算法参数设置

设置 SFLA 蛙群个体数量为 $G=100$,子种群数量 $N=10$,子种群迭代寻优次数 $S=20$,全局混合迭代寻优次数 $Q=100$,每个子种群青蛙个体 $M=10$;个体自适应寻优策略中 $F \in [0.5, 0.8]$, $C \in [0.3, 0.45]$ 。

确定 BP 神经网络隐含层神经元数量,经过反复试验,隐含层神经元数量为 5,人工神经网络训练迭代次数 $T=100$,学习率 $L_r=0.1$,最小目标误差 $E_r=0.0001$;输入隐含层权值 w_1 、隐含阈值 b_1 、输出层隐含权值 w_2 、输出阈值 b_2 分别为 1、5、5、1,蛙群个体向量包括 16 个元素,按照随机概率在 $(-1, 1)$ 之间生成。

4.3 小波变换

选择小波分解算法 db3,将测试样本数据分解为低频分量 A_0 与高频分量 D_1, D_2, D_3 ,将原始风速数据进行小波分解,如图 4 所示。

4.4 算法性能评估

按照上述风速预测模型对风速数据进行小波变换,并进行归一化处理,输入训练样本进行模型训练,分别进行提前 10、30、60 min 风速短期预测,与实测值对比如图 5 所示,数据拟合性能指标与残差分布见表 1、图 6。

由图 5 可知,预测风速与实测值总体趋势保持一致,实测风速跳动较大区域,预测精度较差,总体预测精度较高,不同提前预测时间间隔中 10 min 的拟合结果最佳,60 min 最差,表明随着预测时间间隔的增加,风速数据时序性与自相关性逐渐减弱,基于 60 min 预测基准,10 min、30 min 预测结果平均绝对百分比误差分别提高 33.59%、12.21%,均方根误差分别提高 28.77%、8.22%,对 3 者的风速




图 4 原始风速数据小波分解分量

Fig. 4 Wavelet decomposition component of original wind speed data

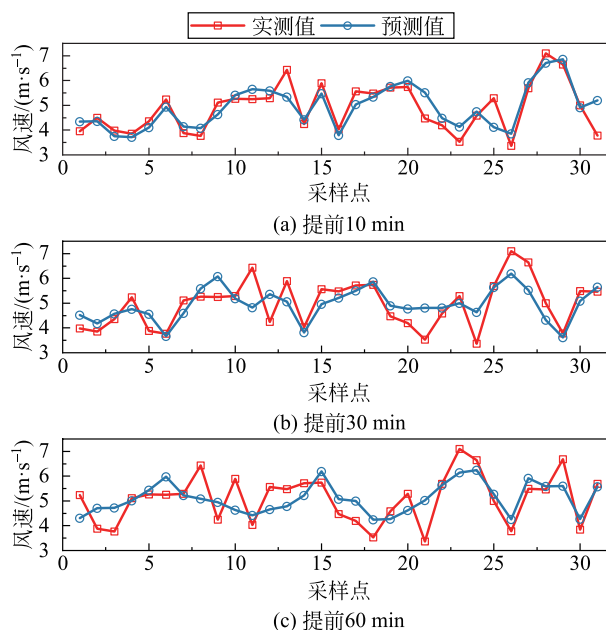


图 5 不同预测时长预测风速与实测值拟合图

Fig. 5 Fitting diagram of predicted wind speed and measured value for different prediction durations

表 1 不同预测时长算法性能对比分析

Table1 Comparison and analysis of the algorithms performance for different prediction duration

预测时长	ϵ_{MAPE}	ϵ_{RMSE}
提前 10 min	0.085 4	0.52
提前 30 min	0.112 9	0.67
提前 60 min	0.128 6	0.73

拟合残差进行进一步的分析,如图 6 所示。

由图 6 可知,10、30、60 min 下的平均拟合误差分




图6 不同预测时长风速拟合误差分布

Fig. 6 Fitting error distribution of wind speed for different forecasting time

别为 0.037、-0.014、0.011 m/s, 总体误差较小, 拟合误差 25%~75% 箱体范围逐渐增加, 表明随着预测时长的增加预测值偏离实测值越大, 且个别风速点预测误差较大。

为进一步验证本文所提组合算法预测的精确性, 与 SFLA 改进的 BP 神经网络算法以及 BP 神经网络算法进行横向对比分析, 均采用小波变换进行高、低频分量分解, 小波变换与神经网络参数设置与前文保持一致, 进行提前 10 min 风速预测, 风速序列拟合结果见图 7, 性能指标见表 2。

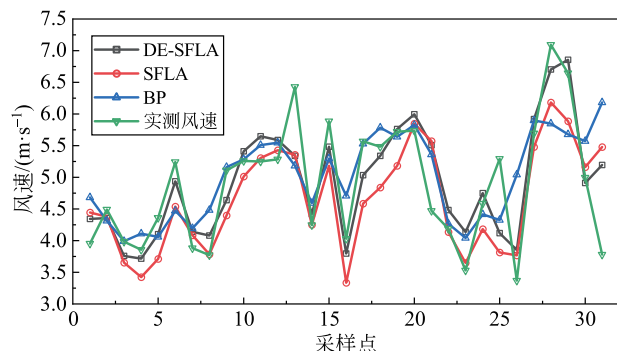


图7 不同算法预测风速序列对比

Fig. 7 Comparison of forecast wind speed series with different algorithms

表2 不同算法预测性能指标计算

Table 2 Calculation of prediction performance indicators of different algorithms

算法	ϵ_{MAPE}	ϵ_{RMSE}
DE-SFLA-BP	0.085 4	0.52
SFLA-BP	0.107 0	0.67
BP	0.119 8	0.76

分析不同算法风速预测结果可知, 本文所提组合算法平均绝对百分比误差、均方根误差均最小,

以 BP 神经网络算法预测结果为基准, DE-SFLA、SFLA 的 ϵ_{MAPE} 指标值分别提高 28.71%、10.68%, ϵ_{RMSE} 指标值分别提高 31.5%、11.84%, 表明相较于 BP 神经网络算法单独进行风速短期预测, 组合算法能够进一步改进算法性能, 提高预测精确性, 通过差分算法改进 SFLA 的子种群寻优策略, 相较于 SFLA-BP 算法能够显著提升神经网络初始权值与阈值的个体优异性, 加快 BP 神经网络训练预测, 提高拟合精度。

5 结论

1) 本文所提基于改进小波分解混合蛙跳差分算法优化 BP 神经网络的组合算法, 通过将波动性高、无序性强的风速序列进行时-域逐级变换分解, 进而通过组合算法分类进行高、低频风速分解量的预测与重构, 显著提高了风速序列预测的精确性。

2) 实测案例表明, 10、30、60 min 不同提前预测时长下, 组合算法总体表现较好, 基于 60 min 预测基准, 10、30 min 预测结果平均绝对百分比误差 ϵ_{MAPE} 分别提高 33.59%、12.21%, 均方根误差 ϵ_{RMSE} 分别提高 28.77%、8.22%, 10、30、60 min 下的平均拟合误差分别为 0.037、-0.014、0.011 m/s, 总体误差较小。

3) 与 SFLA-BP、BP 算法横向对比, 以 BP 算法预测结果为基准, DE-SFLA-BP、SFLA-BP 算法平均绝对百分比误差 ϵ_{MAPE} 分别提高 28.71%、10.68%, 均方根误差 ϵ_{RMSE} 分别提高 31.5%、11.84%, 结果表明本文所提组合算法表现最佳。

参考文献

- [1] 全国新能源消纳监测预警中心, 2021 年三季度全国新能源电力消纳评估分析[EB/OL][2021-10-29]. <https://mp.weixin.qq.com/s/0TiakvEoXW7De4t2Dm7Y6g>.
- [2] 郑若楠. 基于小波分解的超短期风速混合模型组合预测[J]. 分布式能源, 2018, 3(6): 38-46.
ZHENG Ruonan. Combination prediction method of ultra-short-term wind speed by using a hybrid model based on wavelet decomposition[J]. Distributed Energy, 2018, 3(6): 38-46.
- [3] 黄元生, 杨磊, 高冲, 等. 基于经验模态分解和误差校正的短期风速预测[J]. 智慧电力, 2020, 48(1): 35-41.
HUANG Yuansheng, YANG Lei, GAO Chong, et al. Short term wind speed prediction based on EMD and error correction [J]. Smart Power, 2020, 48(1): 35-41.
- [4] 李剑楠, 乔颖, 鲁宗相, 等. 大规模风电多尺度出力波动性的统计建模研究[J]. 电力系统保护与控制, 2012, 40(19):

- 7-13.
- LI Jiannan, QIAO Yin, LU Zongxiang, et al. Research on statistical modeling of large-scale wind farms output fluctuations in different spacial and temporal scales[J]. Power System Protection and Control, 2012, 40(19): 7-13.
- [5] 薛禹胜, 雷兴, 薛峰, 等. 关于风电不确定性对电力系统影响的评述[J]. 中国电机工程学报, 2014, 34(29): 5029-5040.
- XUE Yusheng, LEI Xing, XUE Feng, et al. A review on impacts of wind power uncertainties on power systems[J]. Proceedings of the CSEE, 2014, 34(29): 5029-5040.
- [6] 薛禹胜, 郁琛, 赵俊华, Kang LI, Xueqin LIU, Qiuwei WU, Guangya YANG. 关于短期及超短期风电功率预测的评述[J]. 电力系统自动化, 2015, 39(6): 141-151.
- XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction[J]. Automation of Electric Power Systems, 2015, 39(6): 141-151.
- [7] 冉靖, 张智刚, 梁志峰, 等. 风电场风速和发电功率预测方法综述[J]. 数理统计与管理, 2020, 39(6): 1045-1059.
- RAN Jing, ZHANG Zhigang, LIANG Zhifeng, et al. Review of wind speed and wind power prediction methods[J]. Journal of Applied Statistics and Management, 2020, 39(6): 1045-1059.
- [8] 章国勇, 伍永刚, 张洋. 基于集成经验模态分解和量子细菌觅食优化的风速预测模型[J]. 太阳能学报, 2015, 36(12): 2930-2936.
- ZHANG Guoyong, WU Yonggang, ZHANG Yang. Wind speed forecasting method based on EEMD and quantum bacterial foraging optimization[J]. Acta Energetica Sinica, 2015, 36(12): 2930-2936.
- [9] 肖迁, 李文华, 李志刚, 等. 基于改进的小波-BP神经网络的风速和风电功率预测[J]. 电力系统保护与控制, 2014, 42(15): 80-86.
- XIAO Qian, LI Wenhua, LI Zhigang, et al. Wind speed and power prediction based on improved wavelet-BP neural network[J]. Power System Protection and Control, 2014, 42(15): 80-86.
- [10] 向玲, 李京蓄, 王朋鹤, 等. 基于VMD-FIG和参数优化GRU的风速多步区间预测[J]. 太阳能学报, 2021, 42(10): 237-242.
- XIANG Ling, LI Jingxu, WANG Penghe, et al. Wind speed multistep interval forecasting based on VMD-FIG and parameter-optimized GRU[J]. Acta Energetica Sinica, 2021, 42(10): 237-242.
- [11] EUSUFF M M, LANSEY K E. Optimization of water distribution network design using the Shuffled Frog Leaping Algorithm[J]. Journal of Water Resources Planning and Management-Asce, 2003, 129(3): 210-225.
- [12] 崔文华, 刘晓冰, 王伟, 等. 混合蛙跳算法研究综述[J]. 控制与决策, 2012, 27(4): 481-486, 493.
- CUI Wenhua, LIU Xiaobing, WANG Wei, et al. Survey on shuffled frog leaping algorithm[J]. Control and Decision, 2012, 27(4): 481-486, 493.
- [13] 罗雪晖, 杨焱, 李霞. 改进混合蛙跳算法求解旅行商问题[J]. 通信学报, 2009, 30(7): 130-135.
- LUO Xuehui, YANG Ye, LI Xia. Modified shuffled frog-leaping algorithm to solve traveling salesman problem[J]. Journal on Communications, 2009, 30(7): 130-135.
- [14] 方国华, 林泽昕, 付晓敏, 等. 梯级水库生态调度多目标混合蛙跳差分算法研究[J]. 水资源与水工程学报, 2017, 28(1): 69-73, 80.
- FANG Guohua, LIN Zexin, FU Xiaomin, et al. Ecological dispatch of cascade reservoir based on multi-object shuffled frog leaping-difference algorithm[J]. Journal of Water Resources & Water Engineering, 2017, 28(1): 69-73, 80.
- [15] STORN R, PRICE K. Differential evolution-a simple and efficient heuristic for global optimization over continuous spaces[J]. Journal of Global Optimization, 1997, 11(4): 341-359.
- [16] 杨桦, 任震, 唐卓尧. 基于小波变换检测谐波的新方法[J]. 电力系统自动化, 1997, 21(10): 39-42.
- YANG Hua, REN Zhen, TANG Zhaoyao, et al. A new method for harmonics detection based on wavelets transform[J]. Automation of Electric Power Systems, 1997, 21(10): 39-42.

收稿日期: 2021-09-20

作者简介:

付晓敏(1991),男,硕士,工程师,研究方向为新能源场站经济运行,fxm168400@qq.com。



付晓敏