

分类号_____

密 级_____

UDC_____

学校代码 10500



湖北工业大学
HUBEI UNIVERSITY OF TECHNOLOGY

硕士学位论文

(全日制学术学位)

题 目： 基于水波优化算法改进神经网络的用电负荷预测研究

英文题目： Research on Electro-load Forecasting Based on the
Improved Neural Network by Water Wave Algorithm

学位申请人姓名： 任紫扉

申请学位学科专业： 计算机科学与技术

指导教师姓名： 王春枝

二〇一九 年五月

分类号_____

密 级_____

UDC_____

学校代码 10500



湖北工业大学
HUBEI UNIVERSITY OF TECHNOLOGY

硕士学位论文

题 目 基于水波优化算法改进神经网络的用电负荷预测研究

英文题目 Research on Electro-load Forecasting Based on the Improved

Neural Network by Water Wave Algorithm

研究生姓名（签名） 任紫扉

指导教师姓名（签名） 职 称

申请学位学科名称 计算机科学与技术 学科代码

论文答辩日期 学位授予日期

学院负责人（签名）

评阅人姓名 评阅人姓名

年 月 日

湖北工业大学

学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权湖北工业大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

用电负荷预测与分布是输电线路设计及变电站布点的基础。随着电力行业迅猛发展,电力负荷规划成为电力系统稳定性的重要指标之一,用户级电力负荷预测的研究也越来越受重视。但用户层级负荷波动剧烈,随机性大,不易预测,所以基于用户层级的负荷预测十分困难。用户级电负荷值不仅易受天气,温度,降雨量等环境因素的影响,还易受节假日,经济生产等外界不确定因素影响,因此电量负荷精准预测的关键点在于选取合适的负荷影响因素和建立与之相适应的模型。

本文设计了一种基于水波优化算法(Water Wave Optimization, WWO)改进径向基神经网络(Radial Basis Function Neural Network, RBFNN)的用电负荷预测模型,旨在解决在基于用户层级情况下的用电负荷预测不精确的问题。通过对 RBF 神经网络隐含层中心的优化及扩展常数参数的优化,进一步验证基于水波优化算法改进 RBF 神经网络在基于用户层级的用电负荷预测上,能取得较好的结果。本文的主要工作内容如下:

1.改进模糊C均值聚类算法(fuzzy c-means algorithm, FCM)存在的缺陷问题。通过学习模糊聚类的算法模型,实现原理,算法特征等知识,FCM模糊聚类存在两个弱点:一是在处理大数据集时耗时长。二是易陷入局极值。利用水波优化算法的全局搜索能力使FCM跳出局部极值,并加快聚类的准确率与速度。

2.改进 RBF 神经网络隐含层节点中心的确定及扩展常数随机确定的问题。设计并实现了基于 WWO-FCM 改进的 RBF 神经网络用电负荷预测模型。并对真实的数据进行处理,对用电负荷的影响因素进行分析。解决了在基于用户层级上对于用电负荷的预测时,RBF 神经网络的隐含层参数需要根据实际问题来确定的问题。

本文设计的模型在 UCI 标准数据集上做验证时,本文的预测效果更好,精度更高;该模型用于用户级电量负荷预测上时,预测平均误差更低,预测稳定性更强,同时本文提出的模型网络训练时间更短,收敛速度快。其预测能力能够满足供电企业对电力负荷进行规划和调度的需要,其预测效果可靠、实用,优于传统的预测模型,可以广泛应用于实际电力系统预测。

关键词: 神经网络,用电负荷预测,水波优化算法,模糊聚类

Abstract

Electro-load forecasting and distribution is the basis of transmission line design and substation layout. With the rapid development of electricity industry, electro-load planning has become one of the important indexes of power system stability. However, user-level load fluctuations are severe, random, and difficult to predict, so load forecasting based on user-level is very difficult. The user-level electrical load value is not only susceptible to environmental factors such as weather, temperature, and rainfall, but also susceptible to external uncertainties such as holidays and economic production. Therefore, the key point of accurate prediction of electro-load is to select appropriate load influence factors and establish a suitable model.

In this dissertation, a electro-load forecasting model based on water wave optimization algorithm (WWO) and improved radial basis function neural network (RBFNN) is designed to solve the problem of inaccurate electro-load forecasting based on user-level. By optimizing the hidden layer center of RBF neural network and expanding constant parameters, It is further verified that the improved RBF neural network based on the water wave optimization algorithm can achieve better results in the electro-load forecasting based on the user-level. The main contents are as follows:

1.Improving the defects of fuzzy c-means algorithm (FCM). By learning the algorithm model of fuzzy clustering, the realization principle, algorithm features and other knowledge. There are two weaknesses in FCM fuzzy clustering: First, it takes a long time to process large data sets. Second, it is very sensitive to initialization and easy to fall into local minimum. The global search ability of the water wave optimization algorithm is used to make FCM jump out of the local extreme value and speed up the accuracy and speed of clustering.

2.Improve the determination of the center of the hidden layer nodes of the RBF neural network and the problem of randomly determining the spreading constant. An improved RBF neural network electro-load forecasting model based on WWO-FCM is designed and implemented. The real data is processed and the factors affecting the electro-load forecasting are analyzed. It solves the problem that the hidden layer parameters of RBF neural network need to be determined according to the actual problems in electro-load forecasting based on the user-level.

When the model designed in this dissertation is verified on the UCI standard data set, the forecasting effect of this dissertation is better and the precision is higher; When the model is used for user-level's electro-load forecasting, the prediction average error is lower and the prediction stability is stronger. At the same time, the proposed model network training time is shorter and the convergence speed is faster. The forecasting ability can meet the needs of the power supply enterprise to plan and schedule the electro-load forecasting. The prediction effect is reliable and practical, and it is superior to the traditional forecasting model and can be widely applied to the actual electro-load forecasting system .

Keywords: Neural Networks, Electro-load Forecasting , Water wave optimization algorithm, Fuzzy clustering

目 录

摘 要	I
Abstract	II
目 录	IV
第 1 章 引言	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	2
1.2.1 国外研究现状	3
1.2.2 国内研究现状	3
1.3 研究意义与目的.....	5
1.4 论文研究主要内容.....	6
1.5 章节结构.....	6
第 2 章 水波优化算法概述	8
2.1 浅水波理论.....	8
2.2 水波优化算法基本数学模型.....	9
2.3 水波优化算法性能评测.....	12
2.4 本章小节.....	14
第 3 章 基于水波优化算法改进的模糊聚类模型	15
3.1 模糊聚类模型描述.....	15
3.2 基于水波优化算法改进的模糊聚类流程.....	17
3.3 适应度函数的构造.....	18
3.4 实验结果与分析.....	19
3.4.1 实验环境介绍	19
3.4.2 主要参数设置.....	19
3.4.3 实验内容及过程.....	20
3.5 本章小结.....	24
第 4 章 改进的 RBF 神经网络预测模型设计	25
4.1 神经网络概述.....	25
4.1.1 人工神经网络	25

4.1.2 径向基神经网络	26
4.2 基于 WWO-FCM 的 RBF 神经网络模型设计.....	29
4.2.1 梯度类算法.....	29
4.2.2 进化类算法.....	30
4.2.3 WWO-FCM 改进的 RBF 神经网络算法步骤.....	31
4.3 实验结果与分析.....	32
4.4 本章小结.....	36
第 5 章 基于水波算法改进神经网络的用电负荷预测	37
5.1 电力负荷的影响因素分析.....	37
5.1.1 天气因素的影响.....	37
5.1.2 节假日因素的影响.....	37
5.2 数据处理方法.....	38
5.3 实验结果与分析.....	39
5.4 本章小结.....	42
第 6 章 总结与展望	43
6.1 总结.....	43
6.2 展望	44
参考文献	45
致谢	48
附录	49

第 1 章 引言

1.1 研究背景

当今社会经济飞速发展，人口增加，因而社会对于能源的依赖也越来越大，然而不可再生能源越来越少。所以，能源是否能充分供给，是经济社会的快速发展与可持续发展之间的矛盾，不论是今天还是未来，都是全世界将要面临的共同挑战。电能以其特有的方便性及其可再生的能力应用广泛，与此同时，也使得电网越来越复杂，供电的可靠性越来越难以保障，对应的要求越来越多，不同类型的用户用电的时段，电量等需求也越来越多样化，这给带来了电网运营市场上的前所未有的挑战。所以在电力系统^[1]的构建中，需要合理地对电能的使用进行规划^[2]，目的是保障市场具有安全性、科学性，还能随时满足各种类型用户不同的电力需求。对于用户的需求而言，电能的产生与使用量时时刻刻都有着不同的变化，要求电力系统每时每刻产生的电量必须紧跟系统用电负荷量的变化相匹配，始终保持动态平衡的关系，这样才能保证好供用电的质量，否则将危及电力系统的稳定性，造成安全问题。但是如果产生过多的用电负荷而又消耗不完，在使用范围这么广泛的区域，将会是一种能量的极大浪费。造成了很严重的能源流失。

在“十三五”规划中^[3]，2020 年全国电负荷将达 6.8-7.2 万亿 kw·h，人均耗电量将达到 5000 千瓦时，综合而言，在能源的总体消耗中电能将占据 27%的比例。更重要的是，文件里指出，将在 2020 年总体用电负荷量的基础上预留 2000 亿千瓦时的电量，用于避免因电力短缺造成的问题。由此可见，这样庞大的用电负荷需求^[4]与巨大的用电预留量都将是用户的用电行为不断改变，例如现在实行的按时间段不同，对用电价格进行的调控，使得用电行为更加不具有规律性。对于电量负荷预测将会是一种无形的压力，电量负荷的精准预测也将会变得更加困难。

用电负荷预测基于正确的理论^[5]，经过长期的调查研究，在掌握着大量真实资料的基础上，从用户的用电电需求出发，综合影响电力负荷的种种因素，运用可靠的数学模型，预测方法^[6] 预测未来的用电需求，对用电规划起着不可或缺的作用，因此预测是电力规划的重要基石。用电负荷预测的内容包括了几个用电负荷参数的测算，主要参数是最大有功负荷及其分布、无功负荷及其分布、需电量和电力负荷曲线及其特征值^[7]等。用电负荷预测已经成为了电力规划和运行的重要组成部分之一。

从近些年的发展趋势来看，我国经济结构调整，我国用电市场出现了缓和，电力设备的闲置，造成设备的损耗，影响公司效益。各类用户^[8]构成了各种的复杂的用电需求，及复杂耗时耗电情况。展现出负载不同时间不同区域波动较大的特征。如何供需平衡^[9]是一个待解决的问题。对于电力负荷预测的进行深入研究成为必然。

用电力负荷用量的节节攀升是电力工业发展强有力的依据，电力负荷预测给电力系统规划和运行方面等方面提供了重要的依据，其作用也越发明显。特别是现代科学技术呈喷发式发展，负荷预测技术的研究也日新月异，随着电力负荷预测深入研究，方法也不断涌现。

很多因素^[10]在电力负荷预测时，分别造成不同的影响。如自然气象的因素，地区分布因素，认为生活习惯因素，经济发展因素等，及其他完全无法预知的大事件。

1.气象因素的影响^[11]，引入官方气象预报数据，包括温度、湿度、降雨量等，这些气象因素将直接影响负荷波动，在居民负荷占比很高的地方尤为明显。

2.节假日及特殊条件的影响，与正常的工作日相比，公共假期的负荷都将大大减少，以春节作为例子，春节期间的用电负荷垂直下降变形，但其变化周期与假日周期大致一致。

3.大型工业用户突发事件影响，根据工业工厂大小不同，用电设备数量不同，用电能耗不同，如果发生突发事件，对电量的影响巨大。

4.负荷特性与方法影响。目前，由于缺乏对负荷类型结构的统计分析和许多领域的变化因素的深入分析，当需要历史数据进行比较时，不可能开始工作。不可能总结负载特性和相关的变化规律。

5.管理和政策影响负荷预测是一项技术性很强的工作，但负荷预测在许多地方尚未受重视，也没有规律可言；电量负荷预测的专业技术人员的专业技术性并不高、没有较高的分析能力运用能力和运行经验也十分缺乏，不能满足适应高标准用电负荷准确率的要求。

1.2 国内外研究现状

早在 20 世纪 20 年代初，人们就开始对用电负荷进行研究，直到到 20 世纪 50 年代，越来越多的人认识到电量负荷预测的重要程度，他的重要性不言而喻的，研究人员开展了深入的研究。一般来说，有数学统计方法人工智能方法。但是用电负荷的用户行为和电荷量影响因素复杂多样，预测效果并不理想。现代的人工

智能方法逐渐被越来越多的人利用，体现出其强有效的预测能力。

1.2.1 国外研究现状

电力负荷预测研究技术广泛而又成熟，国外的科学家及学者一直都进行着很高深的研究，按照目前的显现来说，研究神经网络的研究者占比最高。

Hagan Martin T^[12]运用将时间序列分析法，研究自相关函数实现了对区域电力系统的短期预测。

Park^[13]是首位用神经网络做预测的，2001 年，举办的一场预测每天最大电力负荷，预测周期为一个月的竞赛，支持向量机预测模型效果更好，反映了其在小规模数据量预测中的准确性。

D.K.Chaturvedi^[14]等提出了一种基于小波变换的广义神经网络的电力负荷预测算法，结果优秀。

Peter Lusi^[15]专注于日历效应在住宅电力负荷预测上的结果影响影响。使用日期、季节等具有规律性的影响因素得出较粗略的预测，在根据数据进一步精确以逐步降低误差。

Barma^[16]等提出支持向量机区域混合模型，用蝗虫优化算法（GOA）寻优。提出的 GOA-SVM 模型。

Haben^[17]提出混合模型聚类局部电力，主要研究电力峰值驱动力的变量。利用辅助程序进行比对，进一步确定其有效性和准确性。

综上所述，单一的预测模型适应性低，效果不佳。无法适应复杂，要求严格、因素多样的用电人群。组合预测模型更受研究者追捧。其并综合使用新兴而又优秀的方法，最大限度上地提高预测的准确性，这也是当行业发展的方向。

1.2.2 国内研究现状

国内对电负荷的研究相对较晚。自 20 世纪 80 年代开初以来，国内电力负荷研究一直在大步迈进，不断升温。主要有传统方法，如趋势外推法，时间序列法，回归分析法，弹性系数法，灰色预测法等传统方法，人工智能方法在目前也得到了广泛的应用，预测效果也十分明显。

电力负荷随时间变化的情况，有大幅的上升或是大幅的下降，或者有波动较小的情况，李栓、刘莉和刘阳^[18]将趋势外推法应用于电负荷预测。趋势外推法将现有的年电力负荷看作时间序列，并采用最小二乘拟合法求出电力负荷与时间只之间的函数关系，并使用此函数关系来预测下一年的电力负荷。趋势外推法在拟合历史数据方面效果是最优秀的，但是其外推效应的可靠性无法保证。其基本思

想是未来的用电量负荷变化所呈现的规律想是历史的用电负荷负荷变化展现出来的规律的延续。

程超^[19]提出一种基于时间序列法和回归分析法的月度销售负荷预测方法，传统的月度电力销售预测的线性回归模型不考虑舒适温度区间和随机变化。后来，提出用“随机变化水平”量化随机变化的方法，并将其量化值作为月售电量的一个因子包含在回归模型中。通常，在改进上述两种改进的考虑温度及突变量的电负荷模型可以消除不同节日分布对月售电量的影响，从而提高月度售电量预测的准确性。

梁唐杰^[20]采用弹性系数法进行长期电力负荷量的预测，并利用以往电力消耗增长率和以往 GDP 数据增长率计算弹性系数，利用这种计算出的弹性系数以及 GDP 增长率可以得到明年的社会用电总量。

蒋浩然，刘小聪^[21]运用灰色关联度分析法，分析主序列与影响因素序列之间的联系性关系，设计一个灰色预测模型 MGM (1, n)，能很好地进行预测。

徐文权，胡慧，卓张华，杨伟^[22]使用径向基函数(radial basis function, RBF)神经网络采用一种非线性参数优化思想辨识 RBF-AR 模型系数，最后进行预测。对三峡电站数据训练和测试，并与其他经典算法进行比较，验证了 RBF-AR 模型在不确定条件下的预测准确性。

方志强，王晓辉，夏通^[23]分析行业的样本属性特征，将类似行业聚类，依据聚类结果，使用长短期记忆网络模型，学习影响因素以及不同的样本属性特征，设计出了多条件情况下的时间序列预测模型，分析得出较优的电量预测结果。

胡时雨，罗滇生，阳霜^[24]使用多输入双输出的最小二乘支持向量机(LS-SVM)同时预测负荷和的价格并获得初步预测结果。考虑到用电需求，及其响应条件，实时用电价格波动变化与用电量之间的相互影响关系，设计了一种基于数据挖掘技术，模糊循环推理系统的方法，模拟人的大脑思维模式，学习电价与用电量预测二者的博弈流程，多变量最小二乘支持向量机预测算法的初步预测结果是不断进行改变的，直至负荷和电价预测结果趋于稳定。多元最小二乘支持向量机不具有易于陷入局部极值的问题，其特殊之处就是可以自行更正电耗数据的预测结果。与电网的实际用电量使用结果对比来看，该方法具有优良的预测效果。

综上所述，国内国外关于用电负荷预测的方法研究，大多数都是对用电负荷的影响因素进行研究，从传统的数学模型发展到人工智能方法的过渡。对于预测的目的均是为了提高用电负荷的准确率，进而更好地规划和调度电网负荷，使电网的运行更加高效，安全可靠。

1.3 研究意义与目的

在满足一定精度要求的条件下，负荷预测基于系统的运行特性，增容决策、自然条件与社会影响等，确定未来某一特定时刻的用电量数据，用电负荷指的是电力消耗量(功率)或需求电量；负荷消耗量预测是电力系统电量调度中的重要组成部分。通常用电分类为民用负荷、商业负荷、农村负荷、工业负荷以及其他负荷，区分的依据是根据用电负荷的特点和规律。

工业负荷指的是工业上产生的电量，目前，工业用电量已经局域其他各种用电类型的首位，其原因与其工业生产和节假日信息，天气变化等情况密切相关，一般负荷相对稳定。

2018 年，中国的用电增长势头更加突出，据国家能源局的统计数据统计，2018 全社会耗电 68449 亿千瓦时，同比增长 8.5%，准确预测电功耗水平^[27]一直是国内外问题，这是短期功耗预测中最突出的问题。学术界和政策界倾向于对在预测短期用电负荷时，采用中长期电力预测模型，它忽略了短期内对电力消耗产生巨大影响的“结构性”事件。这些研究思路引起了中国学者对电力经济与中长期关系稳定性短期记忆脱钩的共同印象。影响巨大的是中长期“中枢平台区”电力消耗波动的最重要因素。

有研究显示，2013-2015 年间，三年内电量增长的幅度很明显。根据国家统计局的统计，2013 年初，中国工业生产数据 PPI 在触底后反弹，用电价格没有波动，十分稳定，但是全年电量增加 7.5%；2014 年年中，工业生产 PPI 一直回落到 2015 年底，用电量也随之减少，因而，这两年的全社会耗电量增长率减低到 3.8%和 0.5%。

从经济的宏观增长来看，2019 年，我国经济经济“新常态”以来，工业市场发展迅猛，用电压力更大。2019 年中国社会的耗电增长率将在 4.5%至 6.5%。，整个社会的用电能耗将达 7.22 万亿 kw·h，略高于“十三五”规划目标用电趋势。

综上所述，在用电负荷节节攀升的今天，在高负荷的严峻形势下，目前电网平稳运行，供电井然有序，与电网调控中心负荷预测，精心调度，从而有效化解危机密不可分。精确地用电负荷预测，可以保障电网的安全运行和电力的可靠供应，可以对电网的运行方式进行调整和优化，对过载设备进行及时管理，减少设备重载，避免发生过载等问题，做到早筹划，早期部署，早期实施去报了电网安全、稳定、可靠地供电。从能源的角度上来看，由于电能不易储存，合理的电量生产，能有效节约资源，保护环境，满足了可持续发展的要求。

1.4 论文研究主要内容

本文主要介绍了用电负荷预测的相关模型，用电负荷预测面临的问题，以及电力负荷的预测对电网运行的意义。通过分析用电负荷的数据信息和印象因素，设计基于水波优化算法改进神经网络的电力负荷预测模型，详细介绍算法模型理论和实现步骤，并将该模型应用于负荷预测研究中。

(1) 对模糊 C 均值聚类算法的改进。提出的 WWO-FCM 算法，即将水波优化算法融入 FCM 模糊聚类算法中，首先利用水波优化算法找到具有独特全局优化能力的最优解，找到最优解作为 FCM 的中心，然后使用 FCM 步骤进行聚类，得到全局最优解。由于水波优化算法具有跳出局部最优的机制，该算法克服了 FCM 算法对初始值和噪声敏感的不足，克服了 FCM 容易陷入局部最优的缺陷。

(2) 针对径向基神经网络性能的影响因素做了分析，针对参数学习问题，设计出基于 WWO-FCM 改进的 RBF 神经网络学习方法。首先，利用水波优化算法找到模糊聚类算法 FCM 的聚类中心。然后使用无监督学习来确定 RBF 神经网络的隐含层的中心，并根据网络的隐含层的中心之间的距离来确定隐含层中的神经元的扩展常数，最后通过监督学习算法训练网络的隐含层到输出层的权值。随之确定神经网络隐含层节点的中心和扩展常数，进而确定网络的输出权值。

(3) 获取了江苏省扬中市 2015 年 1 月至 2016 年 8 月的电力负荷数值，分析时间因素、节假日因素以和气象因素，最高温度，最低温度，风向，风力强度和天气。

在对用电负荷预测准确度的研究时，设计了一种基于水波优化算法改进模糊聚类的 RBF 神经网络预测模型。这个模型的建立有针对性地解决了江苏省扬中市高新区 1000 多家工业企业对于用电需求预测的问题。设计出基于 WWO-FCM-RBF 神经网络的电力负荷预测模型，WWO-FCM-RBF 神经网络的预测模型保证了预测的准确性，同时确保了速度上的优势，并将其与传统人工智能模型进行比较，分析模型的预测性能。

1.5 章节结构

本文以构建基于水波优化算法和 FCM 模糊聚类算法的 RBF 神经网络设计模型，目的是解决工业电负荷预测更加高效的问题。

本文的内容主要由六个章节组成：

第一章“引言”部分，主要介绍了选题背景意义，国内外用电负荷预测现状，

及章节结构安排。

第二章“水波优化算法概述”部分，以介绍水波优化算法为主。其原理的实现过程以及详细流程，并利用测试函数评估水波优化算法的性能。

第三章“基于水波优化算法的模糊聚类模型”部分，详细介绍了模糊聚类算法的算法流程、优缺点，提出基于了一种水波优化算法的模糊聚类算法，用于改进模糊聚类算法，并介绍了基于水波优化算法的模糊聚类算法的详细改进步骤及适应度函数的构建方法，最后，通过实验对传统的群智能优化算法与本算法进行对比实验，采用 UCI 真实数据集和公开的模拟数据集对算法进行了聚类仿真实验。通过实验得到的聚类的准确性和运行时间进行比较和分析。

第四章“改进的 RBF 神经网络预测模型设计”部分，详细的介绍了人工神经网络、RBF 神经网络的相关理论等，分析了 RBF 神经网络的影响因素，阐述了基于 WWO-FCF 的 RBF 神经网络的过程，构建了完整的改进 RBF 神经网络预测模型。

第五章“基于水波优化算法改进神经网络的用电负荷预测”部分，详细介绍了电负荷的基本情况，电力负荷的主要影响因素为天气因素，节假日因素等。其次，介绍了数据的来源为阿里天池数据，选取的是江苏省扬中市高新区 1000 多家企业的工业用电量，具体描述了对这些数据的处理方法。最后第四章构建的模型对该区域未来一个月的用电负荷做预测，并与传统未改进的模型做对比实验。通过对比几个预测模型的绝对误差率，对仿真结果做进一步总结。

第六章“总结与展望”部分，总结了研究方法及研究成果，并对本文研究工作中可以完善的部分做分析，展望未来。全文结构图如图1.1

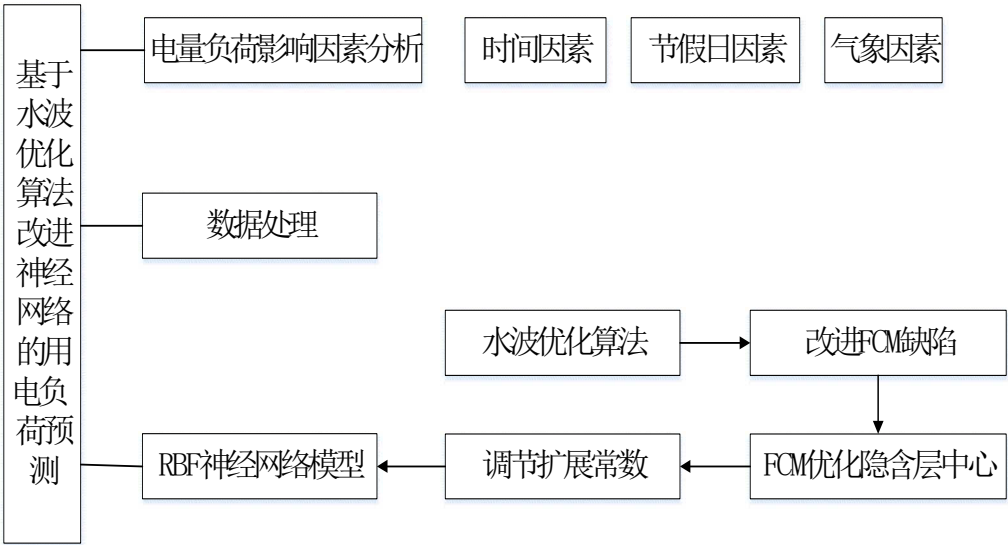


图1.1 全文结构图

第2章 水波优化算法概述

工程优化问题的飞速发展,使其规模不断扩大的同时其复杂程度也不断升级。传统优化算法的提出主要针对组合优化问题。传统的遗传算法,粒子群算法、差分进化算法已经不能解决我们遇到的许多问题,每一种算法只能针对性的解决某一特殊情况。其他旅行、路径、分配、车间生产情况等,均不能取得很好的结果反而会增加计算机和算法的负担,造成耗费大量的时间和精力。这就不得不使我们寻找其他的方法。近年来,受自然、社会、物理等现象的启发而设计的群智能优化算法不断被提出。水波优化算法是最近提出的一种相对最优解算法,其在寻优性能方面具有良好的效果,WWO 在实际工程优化问题上有广阔应用前景。本章将对其进行概述。

2.1 浅水波理论

我国有着漫长的海岸线和分布广泛的江河湖泊,因此水利资源的利用和分配中,诸如波浪的传播以及周围建筑物和浮动物体的影响等研究重点是不可或缺的。在对波浪问题的研究过程中,已经发现在大多数工程问题中,波传播特性反映了沿水平方向的流动尺度远大于水深^[25]的现象。于是学者们将这类问题简化为浅水波问题。浅水波是指水深与波长的比值较小,水底边界影响水质点运动的波浪。它在传播过程中波速、波高、波长等特性随水深的变化而相应变化;当波峰线与等深线不平行时,波浪将发生折射,波向也会随之改变。浅前进波和浅垂直波都属于它的类别。

水波的研究结果中,主要是有四个公式求解得出。但四个条件公式的函数邻域,区间变化很大,参数波高选取范围难以确定,并且几个参数的选取会影响其他参数,最后使得求解的结果变化范围较大,并且极不稳定,会造成耦合现象,最后的问题解决方法将会十分困难。

浅水波问题^[26]的起源于欧拉空间,方法的利用选取了流体力学,分析液体内部每个颗粒的运动方向和过程。在构建水波的模型时,简化了问题的维度,利用数学和物理的研究基础,公式化表达水波的运动过程。并拟将浅水波详细划归为三种理论:长波理论、微幅波理论、振幅理论。例如波峰较尖、波谷平坦、流场中水深方向流体加速度、水平流速与水深关系、沿水深方向平均水平速度、水深方向速度分量与压力分布等非线性特征等影响因素的难易确定得以解决。海洋潮

汐、湖泊静振、浅谈波浪破碎等自然界非线性波动现象得以解释。

以 Boussinesq 方程为代表的水波模型，将水波的色散引入其中，包含了非线性和色散性^[27]。后来的学者分别从非线性和色散性两方面出发做出了改进。利用三次偏微分项和改进流速参数来修正 Boussinesq 方程。这两种模型研究方法的深入研究及其融合方法得以研究出来，并取得了极其优良的效果。

到目前为止，水波模型基本通用了，水波运动的水平方向速度选取方法多种多样，但普遍让研究者们接受的方法是平均速度，少有人利用横截面速度的例子，但是同样能改善精度。但方法并不统一，也有认为增添其他项目的方法提高精度，对于实际工程应用而言，精度完全达到要求。

2.2 水波优化算法基本数学模型

人类模仿自然界，探索出了群智能算法。与传统的梯度算法和随机算法相比，群集智能算法依靠的是全局随机搜索算法，展现出了其优越性。无集中控制约束，保障算法不会因为个别的故障影响整个问题的求解，提升了整个系统的准确率与稳定性；通过间接通信协作方式而非个人之间直接通信，这种间接的信息交互机制保障了系统的可扩展性；在群组中相互合作的个体是分布式的，因此算法也可以并行分布；群集智能理论及其应用研究都具有重要学术和实践价值。

水波优化算法是一种新的自然激发的元模型，方法就是运用自然界中水波的流动规律合理将研究问题优化^[28]。种群中的独立个体都和一个“水波”对象进行比较，运用传播、折射和碎浪三个步骤进行算法须有。水波优化算法控制参数较少；WWO算法的综合性能高于一系列其它新兴进化算法，它体现了WWO算法在应用在优化实际工程问题上的广阔前景。

水波优化（WWO）算法是2015年郑宇军新近提出的一种进化算法，将水波运动过程数学模型化来求解问题^[29]。该算法具有两个属性，即波高和波长，每个解都对应于一个水波。在初始化阶段，算法构建一个水波群，波高设置为一个常数，波长设为0.5。其模型如图2.1所示。




图2.1水波优化模型示意图

WWO通过传播、折射、碎浪等，在空间中搜索^[30]。其框架简单，参数少，种群规模小实现简单，开销较小^[31]。

(2)传播。每个水波将传播一次。波 X 传播后得到 X' ，维度 $d(1 \leq d \leq D)$ 按式 2-1 计算,假设问题解的维度为 2，即 D 为 2。

$$X'_d = X_d + \text{rand}(-1, 1) \times \lambda \times L_d \quad (2-1)$$

$\text{rand}()$ 函数生成一随机数， L_d 表示第 d 维搜索空间的长度。若新水波的位置越界 $[1, N - M + 1]$ ，则重新赋予新的随机位置。

传播后 X' 与原始 X 的适应度值比较。计适应度函数为 f ，若 $f(X') > f(X)$ ，则用 X' 取代 X ，并将的 X' 波高设置为 h_{\max} ；否则保留 X ，并使其波高减 1。

低适应水波具有更长的波长和更低的波高^[32]，高适应位置的水波具有较短的波长和较高的波高，这是水波传播优化的过程。^[33]，若将参数设为 f_{\max} 最大适应度值， f_{\min} 最小的适应度值， α 波长衰减系数， ε 为极小的正整数，水波 X 的波长更新为：

$$\lambda = \lambda \times \alpha^{- (f(x) - f_{\min} + \varepsilon) / (f_{\max} - f_{\min} + \varepsilon)} \quad (2-2)$$

(2)折射，水波在多次传播之后，若寻优效果不佳，则 $h = 0$ 。若将折射时的参数设为 X^* 当前最优水波， $norm(\mu, \sigma)$ 生成均值为 μ ，方差为 σ 的随机数。折射公式为：

$$X_d' = norm\left(\frac{X_d^* + X_d X_d^* - X_d}{2}, \frac{X_d^* - X_d}{2}\right) \quad (2-3)$$

X 向 X^* 学习，能增强算法全局搜索能力及运行速度^[34]。折射后新波 X' 的波高为 h_{\max} ，波长更新为：

$$\lambda' = \lambda \times \frac{f(x)}{f(x')} \quad (2-4)$$

(3)碎浪操作。在 WWO 中，搜索到最优水波 X ，即进行碎浪操作。随机选取 D 中的 k 维，更新公式为 2-5：

$$X_d' = X_d + norm(0,1) \times \beta \times L_d \quad (2-5)$$

设 β 称为“碎浪系数”。一取值范围 0.001~0.01， L_d 设为第 d 维长度。

碎浪的目的就是使得局部搜索能力增强，碎浪的结果时形成 k 个子波；并根据适应度值的大小选择保留原 X 或是取代 X 。

水波优化算法的传播、折射、碎浪有效地平衡了全局搜索能力和局部搜索能力，在保证速度的同时保证准确度，找寻最优位置信息。水波优化模型流程图如图 2.2 所示

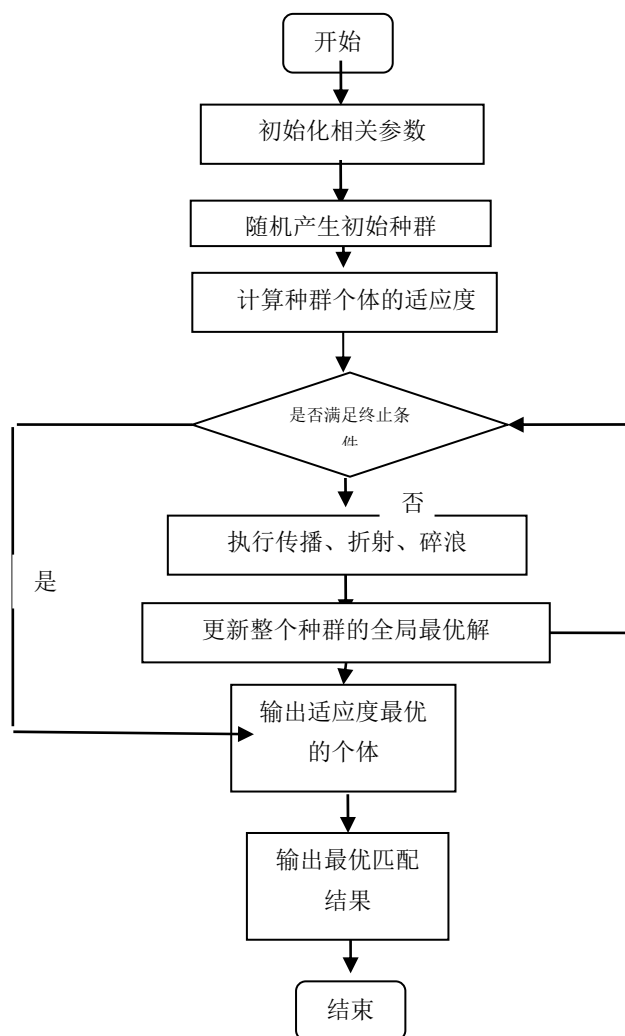


图2.2 水波优化模型流程图

现将 WWO 算法参数设置为：种群规模 N_0 设为5~10，最大波高 h_{max} 设为6~12，波长衰减系数 α 设为1.001~1.01，碎浪系数 β 设为0.001~0.01，最大碎浪维度数 k_{max} 设为 $\min(12, D/2)$ 。

2.3 水波优化算法性能评测的

CEC 2015 函数测试情况如表 2.1，表 2.2 所示。水波优化算法是目前较新的，效果较好的优化算法之一，传统算法还包括 PSO（粒子群优化）、BBO（生物地理学优化）、HS（和声搜索算法）等。在每个测试问题上运行了 50 次比较算法（带有不同的随机种子），记录了 50 次运行中函数值的最大值(max)、最小(min)、中值和标准偏差(std)值。

表 2.1 CEC2015 标准测试函数

类型	函数编号	函数	f^* (最优值)
单模	f_1	Rotated High Conditioned Elliptic Function	100
单模	f_2	Rotated Bent Cigar Function	200
多模	f_3	Shifted and Rotated Ackley's Function	300
多模	f_4	Shifted and Rotated Rastrigin's Function	400
多模	f_5	Shifted and Rotated Schwefel's Function	500

表 2.2 各种优化算法在标准测试函数上的对比结果

函数编号	标准	PSO	BBO	HS	WWO
f_1	max	2.59E+08	1.57E+07	1.55E+07	3.07E+06
	min	2.46E+06	1.8E+06	9.96E+05	2.45E+05
	median	2.87E+07	5.99E+06	4.62E+06	1.13E+06
	std	4.71E+07	3.20E+06	3.22E+06	7.45E+05
f_2	max	1.76E+10	1.86E+06	5.17E+05	6.19E+03
	min	1.52E+04	2.50E+05	1.25E+03	2.01E+02
	median	4.61E+09	7.85E+05	5.81E+04	8.04E+02
	std	3.76E+09	3.87E+05	9.96E+04	1.87E+03
f_3	max	3.21E+09	3.20E+02	3.21E+02	3.20E+02
	min	3.20E+02	3.20E+02	3.21E+02	3.20E+02
	median	3.21E+02	3.20E+02	3.21E+02	3.20E+02
	std	1.51E-01	2.62E-02	7.06E-02	1.03E-05
f_4	max	5.92E+02	4.81E+02	4.96E+02	5.55E+02
	min	4.72E+02	4.21E+02	4.17E+02	4.56E+02
	median	5.26E+02	4.47E+02	4.28E+02	4.96E+02
	std	2.56E+01	1.28E+01	1.17E+01	1.15E+01
f_5	max	5.29E+03	3.60E+03	6.43E+03	4.70E+03
	min	2.69E+03	1.66E+03	1.26E+03	1.54E+03
	median	4.03E+03	2.44E+03	3.96E+03	3.20E+03
	std	5.79E+02	4.63E+02	1.19E+03	6.16E+03

表 2.1 和表 2.2 加图原版 WWO 优化算法论文, 可见在单峰测试函数 f_1 、 f_2 多峰测试函数 f_3 、 f_4 、 f_5 上, WWO 的标准偏差值较其它算法有较大优势, 且其余指标表现也不差, 虽然水波优化算法在处理多峰函数时优势不突出, 但单峰函数上优势非常明显, 展示了他们的解决不同类型的功能优化问题的有效性。总体而言优于 PSO、BBO、HS 优化算法。

2.4 本章小节

本章主要概述了水波优化算法的基础，来源，出处，现状，及算法的过程步骤。它具有简单的算法框架和高维度问题的搜索能力，在面对不同的函数有优化问题时，水波都表现出更好的结果，展现其与其他同类算法之间存在着的优越性。为该算法的进一步应用打下了基础。

第3章 基于水波优化算法改进的模糊聚类模型

模糊C均值算法(FCM)^[35]应用十分广泛、也十分敏感。致命缺陷是非常敏感且易陷入局部极值。而水波优化算法是全局优化方法,优点是简单、通用性和并行处理的适应性。因此将水波优化算法融合入模糊聚类算法中,平衡了局部寻优能力及全局寻优能力,收敛的更快,更好地进行聚类。本法将水波优化算法融合入FCM算法中^[36],可以优化FCM算法聚类中心,最终得到全局最优解,从而克服了FCM算法的不足。

3.1 模糊聚类模型描述

聚类是一种无监督的自发知识发现算法^[37]。根据数据之间的相似性关系,即可将不同类型的数据对象划分到不同的类中。这种聚类的方法不对数据做标准度的划分和聚类数的划分,同时也不需要数据样本进行训练,只用根据数据之间的互相联系关系,主动学习其相似性,即可对胡乱的数据实现聚类。采用了不同的聚类算法,结果基本相同。

模糊聚类是一种数学方法,它使用模糊数学来根据某些要求来描述和分类事物^[38]。模糊聚类算法首先会构造模糊矩阵^[39],再次就是明确各个属性之间的聚类关系,这样就建立起了数据之间的模糊关系,最后根据数据对象与类之间的隶属度关系建立模糊数学模型,最后分类结果得以确定^[40]。将数据集划分为多个类或集群,以使类之间的数据差异更大,类内差异小,利用的是“最小化类间相似性,最大化类内相似性”原则。

传统的硬分区方法的典型代表是C均值算法^[41]。实际上,大多数待分类的数并没有严格的属性,这种划分不可能反映数据与分类的关系^[42],软划分思想被提出。模糊C均值算法^[43](fuzzy c-means algorithm, FCM),是基于目标函数优化作为依据的一种数据聚类方法^[44]。聚类结果是每个数据点到聚类中心的隶属度(或元素x属于某一个类的概率),所以该隶属程度是数值型的数据,一个数据对象隶属度之和为1。其应用且较为成功^[45],它通过优化获得类中心的每个样本点的隶属度,确定类属,达到自动分类。

模糊C均值算法的优点是相应的值不离散^[46],它详细地描述了各类数据的不同属性之间的内在联系。因而每个属性对象对于聚类结果有着很大的影响,但同时这种内在的规律是模糊聚类的分类更加可信和具有较高准确度。

模糊聚类的算法过程为：首先将所有数据进行一次没有规律的划分，找出聚类中心，根据聚类中心点与其他数据之间的距离计算隶属度矩阵^[47]，没重新进行一次聚类就会更新一次。直至隶属度矩阵值未达到阈值范围时，聚类结束。算法流程图如下图 3.1 所示：

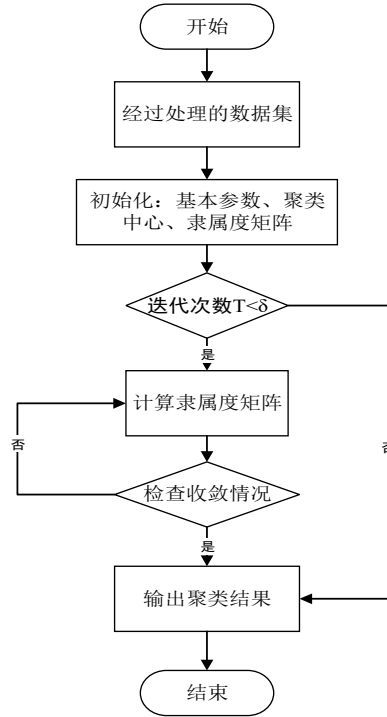


图 3.1 FCM 算法流程图

FCM 算法流程为在样本 $X = \{x_1, x_2, \dots, x_n\}$ 中，属性个数未 s 。目的为将样本 X 聚于 $c(2 \leq c \leq n)$ 个类中， $v = \{v_1, v_2, \dots, v_c\}$ 用来表示聚类中心的集合。方式 3-1 表示初始化隶属度。

$$u_{ij} \in [0, 1], \sum_{i=1}^c u_{ij} = 1 \quad (3-1)$$

其目标函数为

$$J(U, V) = \sum_{j=1}^n \sum_{i=1}^c u_{ij}^m d_{ij}^2 \quad (3-2)$$

其中， $d_{ij} = |x_i - v_i|$ 为样本点 x_j 与中心 v_i 之间的欧式距离， m 是模糊度的权重指数。当 $m \rightarrow 1$ 时，FCM 表示硬划分。在实际应用中， m 通常取 $[1.25, 2.5]$ 。 $m \geq 1$ 是模糊加权参数。则 FCM 算法就是求在满足 (3-1) 时，公式 3-2 取值最小。

J 达到最小的条件是，需满足公式 (3-3) 的条件。

$$v_i = \frac{\sum_{j=1}^n u_{ij}^m x_j}{\sum_{j=1}^n u_{ij}^m}, i = 1, 2, \dots, c \quad (3-3)$$

v_i 表示类中心。

当 $d_{ij} \neq 0$ 时

$$u_{ij} = \left(\sum_{k=1}^c \left(\frac{\|x_j - v_i\|}{\|x_j - v_k\|} \right)^{\frac{2}{m-1}} \right)^{-1}, j = 1, 2, \dots, n \quad (3-4)$$

U 表示隶属度矩阵。 $d_{ij} = 0$ 时, $u_{ij} = 0, k \neq j, i = 1, 2, \dots, n$

3.2 基于水波优化算法改进的模糊聚类流程

模糊C均值聚类算法是众多模糊聚类中最优秀的一种^[48]。但它需要解决的问题是:降低大数据处理时间。第二个降低初始敏感度和陷入极值。

面对这些问题,已经提出了各种改进,目前的改进技术虽然种类丰富,有的用时非常短,但初始化依然十分敏感。因此,本章利用一种全局优化算法,克服初始敏感的问题。

WWO算法是一种基于浅水波理论的全局进化算法,该算法将个体与“水波”对象进行类比,性能高于其他众多群智能优化算法。因此,将水波优化算法与模糊聚类算法相结合,不仅可以解决FCM对初始值敏感的缺陷,也可以使FCM算法跳出局部最优解并找到全局最优解。提高聚类的严密科学和准确度。

本章设计的基于水波优化算法改进模糊聚类算法(WWO-FCM)模型,思想为首先随机产生一组水波种群及确定归一化数据,然后根据初始数据计算每个水波的适应度函数,在规定的搜索空间内,根据适应度值,进行水波的传播、折射、碎浪等操作寻找最优解,并据此更新中心及原始模糊聚类隶属度,在满足条件之后,输出最终聚类中心集合并完成聚类。

WWO-FCM算法步骤:

Step 1 在水波优化中,一个解对应一个水波,每一个个体具有的三个特征是:适应度值 $f(x)$,波高 h ,波长 λ 。初始化波高 h 为一个常数(h_{max}),波长 λ 也为一个常数。计算各个个体水波的适应度值,开始迭代,如果满足终止条件则返回最优解,算法结束。

Step 2 对种群中每个水波 X 执行下列操作,按公式(2-1)执行传播操作,生成 X' ,如果 $f(X') > f(X^*)$,执行碎浪操作,并替换 X ,否则进行折射操作。

Step 3 更新整个种群的全局最优解，输出适应度最优的个体，输出最优的匹配结果 v_i^0 。

Step 4 输入聚类数目 c ，模糊因子 m ，和迭代终止条件，聚类中心为 v_i^0 。

Step 5 用式 (3-4) 计算 u_{ij} ，用式 (3-3) 计算 v_i^1 。

Step 6 $\|v^1 - v^0\| \leq \delta$ 是，转步骤 7，反之使 $v_i^0 = v_i^1$ ，重复上一步。

Step 7、结果 (V, U) 输出。

WWO-FCM 流程图如图 3.2 所示：

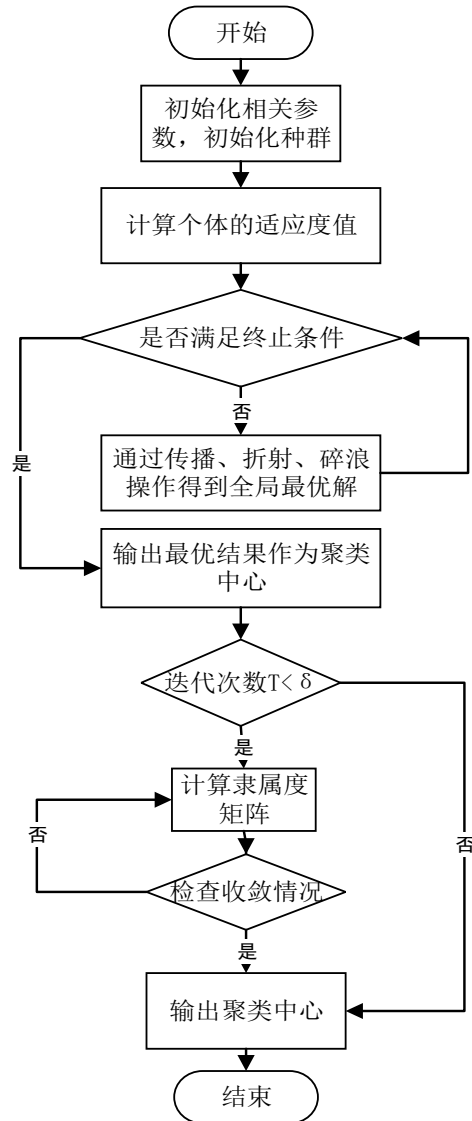


图 3.2 WWO-FCM 流程图

3.3 适应度函数的构造

生物学家使用“适应度”一词来衡量物种适应环境的程度。对生活环境具有

较高适应性的物种将有更多的繁殖机会，而对生活环境适应较少的繁殖机会甚至可能灭绝。类似地，适应度的概念也用于水波优化算法中，以测量组中的个体在优化计算中有可能达到或接近于或有助于找到最优解的程度。

对于模糊聚类，适应度函数可以较为普遍地反映结果优秀程度。本文使用 FCM 算法的目标函数来定义个体的适应度函数。

WWO 首先初始化一组波，其高度都设置为的偏移量来创造一个新的波 X 。为了评价每次迭代效果的优劣，适应度函数为公式 3-5:

$$f(x_i) = \frac{1}{J} = \frac{1}{\sum_{j=1}^n \sum_{i=1}^c u_{ij}^m d_{ij}^2} \quad (3-5)$$

式中， J 是式子的目标函数值； J 越小， $f(x_i)$ 就越高，聚类效果越好。

3.4 实验结果与分析

3.4.1 实验环境介绍

硬件描述:

实验环境为一台配置为 Inter Core I5-4590 3.30GHZ 主频处理器、8GB 运行内存，Windows7 64 位操作系统，Matlab R2015a 的电脑。PC 机配置 3.1 所示。

表 3.1 硬件配置

名称	型号
设备	联想台式电脑
CPU	Intel
内存	8G
硬盘	ST1000DM003-1ER162 1T
操作系统	Windows 7 旗舰版

3.4.2 主要参数设置

在验证基于水波优化算法改进模糊聚类算法模型的效率及开销优于普通模糊聚类算法，本小节选用 GA-FCM 算法、PSO-FCM 算法、WWO-FCM 算法分别对 Glass、leuk72_3k、X4k2_far 三组实验数据集进行聚类实验，在参数设置时，设最小误差 $\varepsilon = 10^{-6}$ ，模糊指数 $m = 2$ 。相应地 PSO-FCM 算法参数设置:粒子群群体大小 $n=20$,最大迭代次数为 500 次,学习因子 $C1 = C2 = 1.5$,惯性权重 $W_{max} = 0.9, W_{min} = 0.4$;

WWO-FCM 算法参数设置如下表 3.2 所示。

表 3.2 WWO-FCM 算法参数设置

参数	Glass 数据集	leuk72_3k 数据集	X4k2_far 数据集
N0	6	3	4
hmax	12	12	12
d	13	39	2
n	2	2	2
λ	0.5	0.5	0.5
α	1.01	1.01	1.01
β	0.1	0.1	0.1
Kmax	7	12	1

3.4.3 实验内容及过程

为了验证WWO-FCM算法的有效性和可行性，采用UCI标准数据集中：一组实际数据集Glass和模拟数据集中：两组数据集leuk72_3k、X4k2_far对本文算法进行测试。数据集信息概况如表3.3。

表3.3 Glass、leuk72_3k和X4k2_far数据集的信息

数据集名称	样本个数	类	维数
Glass	214	6	13
leuk72_3k	72	3	39
X4k2_far	400	4	2

Glass 数据集由犯罪现场留下的玻璃碎片样本构成，共 214 个样本，包含 6 类玻璃样本，分别是 70 个浮法建筑物门窗玻璃样本(building_windows_float_processed)、76 个非浮法建筑物门窗玻璃样本(building_windows_non_float)、17 个浮法车窗玻璃样本(vehicle_windows_float_processed)、13 个容器玻璃样本(containers)、9 个餐具玻璃样本(tableware) 和 29 个灯具玻璃样本(headlamps)。每个玻璃样本有 10 个属性，分别是身份标号(Id-number)、折射率(RI)、钠的含量(Na)、镁的含量(Mg)、铝的含量(Al)、硅的含量(Si)、钾的含量(K)、钙的含量(Ca)、钡的含量(Ba) 和铁的含量(Fe)。而 leuk72_3k、X4k2_far 两组数据则是公开的两组模拟数据集。

将三种算法分别运行 30 次，图 3.3 为本算法对 Glass 数据集进行分类的结果图、图 3.4 为三种算法分别对 Glass 数据集分类目标函数对比曲线图，图 3.5 为本算法对 leuk72_3k 数据集分类的结果图、图 3.6 为三种算法对 leuk72_3k 数据集分类目标函数对比曲线图，图 3.7 为本算法对 X4k2_far 数据集分类的结果图、图 3.8 为三种算法分别对 X4k2_far 数据集分类目标函数对比曲线图，

将三种算法聚类的聚类正确率、目标函数最优值、迭代次数、运行时间做

统计。Glass 数据集统计结果如表 3.4 所示；leuk72_3k 数据集统计结果如表 3.5 所示；X4k2_far 统计结果如表 3.6 所示。




图 3.3 WWO-FCM 算法对 Glass 数据集的聚类结果




图 3.4 Glass 数据集目标函数变化对比曲线

表 3.4 Glass 数据的聚类结果

算法	平均准确率%	目标函数最优值	迭代次数	运行时间 (s)
GA-FCM	83.97	154.146	93	7.44

PSO-FCM	85.00	152.286	88	6.17
WWO-FCM	90.35	151.146	92	7.15




图 3.5 WWO-FCM 算法对 leuk72_3k 数据集的聚类结果




图 3.6 leuk72_3k 数据集目标函数变化对比曲线

表 3.5 leuk72_3k 数据的聚类结果

算法	平均准确率%	目标函数最优值	迭代次数	运行时间(s)
GA-FCM	78.61	814.77	36	3.38
PSO-FCM	86.63	806.97	34	3.17

WWO-FCM	89.48	804.54	33	3.92
---------	-------	--------	----	------



图 3.7 WWO-FCM 算法对 X4k2_far 数据集的聚类结果




图 3.8 X4k2_far 数据集目标函数变化对比曲线

表 3.6 X4k2_far 数据的聚类结果

算法	平均准确率%	目标函数最优值	迭代次数	运行时间 (s)
GA-FCM	95.32	122.93	17	3.28
PSO-FCM	97.25	110.76	16	3.13
WWO-FCM	99.04	100.00	14	2.52

根据表 3.4-表 3.6 的实验结果可以看出,WWO-FCM 算法目标函数值收敛于全局最小值,精确性优于 GA-FCM 算法和 PSO-FCM,分类结果也更加准确。

从收敛效果上来看,对于 Glass 数据集,WWO-FCM 算法虽然运行时间较长,且运行迭代次数比其他两个算法多,但其准确率得到了提高。对于另外两个数据集,虽然也偶有运行时间较长的现象,但是迭代次数和准确率一直都是最高的。所以,从整体上而言,WWO-FCM 算法的聚类效果更好。将其应用于 RBF 神经网络的隐含层确定,可以精准地确定隐含层中心,使得预测结果更精确。

3.5 本章小结

本章主要的研究内容是 FCM 模糊聚类算法,对该算法的算法原理、算法过程及优缺点进行了详细的阐述,其次,介绍了该算法的一般改进方法及现状。提出的 WWO-FCM 算法将水波优化算法融入 FCM 模糊聚类算法中,首先利用水波优化算法找到具有独特全局优化能力的最优解,找到最优解作为 FCM 的聚类中心,然后使用 FCM 步骤进行,从而能找到最优结果。新构建的模型使 FCM 算法对初始值和噪声灵敏度的不足得到改善,克服了 FCM 容易陷入局部最优的缺陷。实验结果证明,WWO-FCM 不仅有很强的全局搜索能力,而且聚类精度高于传统的 GA-FCM 和 PSO-FCM 算法,在部分聚类数据集上速度得到提高,在所有聚类效果上都得到明显提高。为下一步改进 RBF 神经网络的隐含层中心奠定基础,然后优化扩展常数参数。

第 4 章 改进的 RBF 神经网络预测模型设计

通过与多层前向神经网络结构作对比发现，RBF 神经网络的基本架构是一种典型的三层静态前向神经网络。构成 RBF 神经网络的基本思想是不通过权连接的方式连接，而是采用将输入矢量直接映射到隐含层空间，用径向基函数作为隐单元的基，构成隐含层空间。这样，当径向基函数的中心确定了，神经网络的网络结构基本确定。

本章设计一种优化改进的 RBF 神经网络，在标准网络中对隐含层中心聚类，进而利用传统算法确定网络初始结构。首先利用模糊聚类算法对求出的初始隐层节点进行水波优化聚类，以便在进化过程中，可以尽可能将类似的隐节点聚合在一起，这样有利于提高算法的精度，减少网络的复杂结构，使算法快速收敛，同时能更准确地确定隐含层的中心，这样，RBF 神经网络的扩展常数也就随着确定。从实验结果可知，算法具有复杂的样本聚类能力，且收敛迅速，在预测精度和收敛速度上表现出明显的优势。

4.1 神经网络概述

4.1.1 人工神经网络

人工神经网络(Artificial Neural Networks, ANN)是一种通过模拟人的的思维方式的特点上加上生物(人或者动物)的神经网络的行为特性，能够实现信息的分布式处理的一种神经网络(NN)。人工神经网络具有联想记忆的功能，能够进行非线性映射，在分类识别，优化计算方面及知识处理和逻辑学推演等方面表现出更强的优势。因此，使得网络在处理传统数学方面的非线性难题变得驾轻就熟。设计合理的神经网络变得尤为关键。神经网络是通过在数据中抽取一定的数据作为训练样本，训练样本通过输入及输出的结果进行自学习。在此基础上，训练样本数据会随时调整网络自身的权值，这正是训练的意义所在。最终，网络会以任意精度无限接近本文提到的非线性映射。神经网络会在自身的样本数据自学习的过程中从输入和输出端抽取定义的映射法则，并将结果存储到所有连接的网络上，即分布式存储。由于现实设计中所有的现象抽象出的模型都表现为非线性的特点，因此，神经网络得到了广泛的应用，例如：负荷预测，股市预测，天气预报以及化学过程等工业过程的建模。

神经网络的模型根据不同的角度可以分为不同的类别，目前有近 40 中类别。根据网络的拓扑结构可将神经网络分为前向网络(feedforward network)和反馈网络(feedback network)。前向网络可以抽象成一个有向无环路图，主要特点是网络中无反馈。网络中的信号从输入空间到输出空间的变换是通过简单非线性函数的多次复合来实现。前向网络与 ANN 网络的由大量神经元构成的网络变换原理类似。因此，可以达到模拟各种各样的行为目的。反馈网络可以抽象成一个无向完备图，主要特点是网络中的神经元之间存在反馈机制。正因如此，网络才具有联想记忆的能力。网络根据神经元的变化来处理数据。

人类或者动物通过对自身所处的生存环境进行信息的获取和提炼，形成指导自身实践的经验或规则的过程被称为知识处理^[49]。神经网络具有这种能力。神经网络提取的规则本质上是一种非线性的映射关系，这种映射关系一旦确立，其网络结构也就随之确定。神经网络模型的主要目的就是通过学习样本的自学习来调整网络的权值，使映射关系变得可靠，更加逼近数据的变化规则。训练样本通过自学习调整权值的过程属于知识处理的过程。测试集（没有参加训练的另一部分数据）是验证神经网络可靠性的依据。通过对比经过训练的神经网络输出结果和没有参与训练的测试集来判断网络的可靠性。如果数据结果接近，则表示训练网络的可靠性高。神经网络还具备知识提取的能力，即网络能够在没有先验知识的情况下，从原始测试集数据中提取规则，并发现规律。

神经网络建模具有“黑箱”特性。所谓“黑箱”特性，即网络只需要关注输入因素和输出因素而不需要过多的关注绝缘的网络内部具体架构，机器动力性特征。这正是网络的强大知识处理能力的优势所在。因此，网络具有较强的通用性。经过近年来国内外学者的研究付出，BP 神经网络和 RBF 神经网络在函数逼近特性上都有了明显的进展，和 BF 网络相比，RBF 网络因具有训练速度快和泛化能力强等特点使得其逼近能力更佳，应用更佳广泛。

4.1.2 径向基神经网络

RBF 神经网络是一种单隐层、以函数逼近为基础的前馈神经网络，于 20 世纪 80 年代末提出。随着研究的逐渐深入，RBF 神经网络因其结构简单，非线性逼近能力强以及良好的推广能力等特点，引起了各方面研究者的高度重视。被应用于许多研究领域，如模式分类、函数逼近和数据挖掘等。

RBF 神经网络是一种标准的多输入，多输出的前馈神经网络，由输入层，径向基层（又称非线性隐层）和线性输出层所构成。其中，大部分非线性隐层的激活函数是一种具有对称性质的 RBF，线性输出层的神经元数与输出向量维数相

同，其主要作用为对隐层节点的输出进行线性加权。标准的 RBF 神经网络结构如图 4.1 所示，其中，系统的多输入为 $x \in R^m$ 。多输出为 $y \in R^n$ ，输入与输出之间的函数关系为 $f: x \rightarrow y$ 。




图 4.1 RBF 神经网络拓扑结构

RBF 神经网络隐层对将输入空间 R^m 中的样本点变换到高维特征空间，同时对输入向量进行非线性变换。对训练样本在特征空间中采用线性模型的方式进行建模分析，并在高纬度特征空间中使训练样本线性可分。其激活函数是一组对称的 RBF。RBF 的一个重要特征是随着距中心点的距离增加，函数值呈单调递减(递增)。典型的 RBF 包括:

(1) Gaussian 函数:

$$\varphi(x) = \exp\left(-\frac{r^2}{2\sigma^2}\right) \quad (4-1)$$

(2) Multiquadric 函数:

$$\varphi(x) = (x^2 + c^2)^{\frac{1}{2}} \quad (4-2)$$

(3) Inverse Multiquadric 函数:

$$\varphi(x) = (x^2 + c^2)^{-\frac{1}{2}} \quad (4-3)$$

Gaussian 函数的 RBF 具有良好的局部特征，响应仅在中心点附近的领域中比较显剧，而函数值随着距离中心点的距离的增加而单调减小，直至趋于零。因此这中类型的 RBF 在实践中被广泛应用。在 20 世纪 80 年代，Powell 提出了一种严

格的多变量差值的 RBF 方法。Broomhead 和 Lowe 首先在神经网络设计中使用了 RBF，并比较了 RBF 和多层神经网络；其次初步分析了 RBF 与传统差值领域在神经网络设计上的不同特点，据此提出了一种两层结构的 RBF 神经网络。1989 年，Moody 和 Darken 根据感受野的局部调整及交叠等特性提出了具有局部响应特性的神经网络。同时在证明使用 RBF 神经网络能获得较快的学习速度的基础上初步提出了 RBF 神经网络的训练算法。1995 年，Girosi 等为了改进 RBF 神经网络泛化能力，在网络中应用了正则法则。之后的研究者又提出许多改进的算法。

随着研究日渐成熟，RBF 神经网络被用于众多领域，诸如序列预测、模式识别、数据挖掘等。Varvak 设计将 RBF 神经网络算法应用于数值分析和模式识别中。Montazera 和 Giveki 通过改进 RBF 神经网络隐节点中心和径基宽度的确定方法，在提高 RBF 神经网络算法收敛速度的同时，提升了 RBF 神经网络算法的图像检索性能。Senapati 等在医疗诊断中应用 RBF 神经网络，取得了较好的效果。Deng 等在随机模型的区间分析中利用 RBF 神经网络对结构化参数进行了区间估计。Kadir kamanathan 和 Niranjana 利用 RBF 神经网络构建函数估计模型进行序列分析。Jia 等将神经网络模型应用于解决数据挖掘领域的小样本分类问题，提出了基于 GA 和偏最小二乘法的 RBF 神经网络模型。

RBF 神经网络是一种结构简单、收敛速度快且不受初始权值的影响的三层静态前向网络。其输入层节点数根据模型定义输入变量的数目呈现单调递增趋势，为网络的第一层，主要组成部分为信号源节；隐含层是 RBF 神经网络的重要研究点，其节点数根据模型的复杂程度而具体变化，为网络的第二层；输出层的作用是根据输入模式的变化做出具体的响应，为网络的第三层。输入层需要经过非线性变换处理才能到达隐含层，这部分工作由径向基函数完成。反之，从隐含层经过线性变换就可以到输出层空间。基于以上分析，网络的权值可由线性方程组直接解出，RBF 神经网络避免了局部极小问题，同时大大加快学习速度。

RBF 神经网络的径向基函数基本形式可由下式表示：

$$F(x) = \sum_{i=1}^N w_i \varphi(\|x - c_i\|) \quad (4-4)$$

其中， c_i 表示基函数的中心， w_i 为权值向量， $\varphi(\|x - c_i\|)$ 表示为 N 个径向基函数的集合，高斯函数被选择作为网络的基函数，则神经网络的第 i 个隐含层节点输出形式为：

$$y_i^2(x_k) = e^{-\frac{\|x - c_i\|^2}{2\sigma^2}}, k = 1, 2, \dots, n \quad (4-5)$$

(2)RBF 神经网络的隐含层到输出层为线性映射，相应输出层输出为：

$$y_j^3(x_k) = \sum_{i=1}^n w_{iq} y_i^2(x_k) + b_q, j = 1, 2, \dots, n \quad (4-6)$$

(3)其中， w_{iq} 表示隐含层第 i 个神经元与输出层第 q 个神经元的连接权值， b_q 为输出层第 q 个神经元的阈值。

4.2 基于 WWO-FCM 的 RBF 神经网络模型设计

在具体的网络模型设计中，可以根据实际问题来确定 RBF 神经网络的输入层和输出神经元个数。如果隐含层神经元个数过多，则不但使网路规模变得非常庞大造成计算成本的增加，而且是网络的过度学习造成泛化能力差等缺陷。如果隐含层神经元个数过少，则造成网络非线性拟合能力差，RBF 神经网络学习不充分。经研究发现，当 RBF 神经网络的隐含层节点数 K 值，中心 μ_k 和宽度 σ_k 确定时，网络就可以看成一个从输入到输出的线性方程组，再通过最小二乘法就可以求解隐层到输出层的连接权值。

影响 RBF 神经网络的性能的主要因素有神经元个数和中心位置、扩展展常数参数。

基于 RBF 神经网络隐含层神经元数据中心的选取方法不同，可将网络的参数学习算法分为梯度类算法和进化类算法两大类。

4.2.1 梯度类算法

1988 年 Moody 和 Darken 提出了 K-means 聚类算法，该算法是一种比较经典的 RBF 神经网络参数学习算法。首先，RBF 神经网络隐含层的中心 μ_k 采用无监督学习来确定（即：原始训练样本采用 K-means 聚类算法进行聚类处理）。其次，隐含层各神经元的扩展常数 σ_k 根据网络隐含层的中心之间的距离来确定。最后，通过梯度下降法训练网络的隐含层到输出层的权值 ω （即：有监督学习算法）。

K-means 聚类算法的核心目的是确定网络的输出权值，而权值的确定依赖于隐含层的中心及其扩展常数，这只需要算法对原始样本进行聚类就可以实现，具有操作简单，容易实现的优点。但 K-means 聚类算法的缺点是，算法不稳定，鲁棒性差。具体表现为，初始的聚类中心值取值不同会造成计算出的聚类中心值各部相同。算法必须多次运行并取最小值来避免陷入局部最优解，大大增加了网络餐算的据算复杂度。

4.2.2 进化类算法

梯度类算法是一种根据传统的基于数学规划的算法，而进化类算法是一种全局的优化算法（典型全局算法还有蚁群算法，蜂群算法，人工鱼群算法，PSO 算法等），是通过模拟自然生态系统的进化机制的特性进行归纳总结，抽象出的一种算法模型。进化类算法调整粒子的搜索方向采用构造最小化的适应度函数，具有稳定性高，收敛快的特点，被大量应用在对函数的极值寻优问题，神经网络参数学习及对模型的预测控制上。其中，遗传算法(GA)及粒子群优化（PSO）算法在此方面表现更为突出。

遗传算法是一种通过模拟达尔文进化论适者生存，优胜劣汰特性的全局搜索算法。该算法主要通过二进制编码模拟基因编码特性到达种群中的个体进行变换的目的。通过模拟遗传学中的选择，交叉及变异等特性实现算法的全局搜索过程。由于 GA 算法在实际的进化过程模拟中采用二进制编码，但在进化结束后又需要将二进制的编码形式转换成十进制的编码形式，这些操作大大增加了算法在寻优过程中的计算复杂度，并且具有收敛慢的缺点。

与遗传算法相同的是，PSO 算法也是一种全局搜索算法，但与遗传算法不同的是，PSO 算法是通过模拟鸟群或鱼群等群体觅食行为，且算法在进行粒子寻优的过程中采用十进制的编码方式。算法能够通过自身的经验，结合种群中的其他粒子传递的信息等来调整搜索方向。具有控制参数少，寻优过程简单，收敛快的特点。但算法的缺点是容易陷入局部最优解，且容易过拟合。在处理存在多极值点的实际复杂问题中无法跳出局部极小值点。因此，在基于以上分析的基础上，提出基于进化算法的梯度类算法。其主要目的是使 RBF 神经网络跳出局部最优解的缺陷，又可以降低网络参数学习的复杂度。首先，模糊聚类算法 FCM 的聚类中心采用水波优化算法确定。其次，RBF 神经网络隐含层的中心 μ_k 采用无监督学习（即：原始训练样本的聚类操作采用 FCM 聚类算法）来确定。再次，隐含层各神经元的扩展常数 σ_k 根据网络隐含层的中心之间的距离来确定。最后，利用梯度下降法训练网络的隐含层到输出层的权值 ω （即有监督学习算法），以此来确定神经网络隐含层节点的中心和扩展常数，在此基础上确定网络的输出权值，操作简单，易于实现。

4.2.3 WWO-FCM 改进的 RBF 神经网络算法步骤

假设 t 为迭代次数, 则第 t 次迭代时聚类中心为 $\mu_1(t), \mu_2(t), \dots, \mu_k(t)$, 相对应的聚类域为 $W_1(t), W_2(t), \dots, W_k(t)$ 。确定 RBF 神经网络隐含层的中心和扩展常数的 WWO-FCM 聚类算法具体步骤如下:

Step 1 在水波优化中, 一个解对应一个水波, 每一个个体具有的三个特征是: 适应度值 $f(x)$, 波高 h , 波长 λ 。初始化波高 h 为一个常数 (h_{max}), 波长 λ 也为一个常数。开始迭代计算各个个体水波的适应度值, 直到有满足终止条件的水波, 并返回最优解, 算法结束。

Step 2 对种群中每个水波 X 按公式 (2-1) 执行传播操作, 并生成 X' , 如果 $f(X') > f(X^*)$, 则执行碎浪操作, 并替换 X , 否则进行折射操作。

Step 3 更新整个种群的全局最优解, 输出适应度最优的个体, 输出最优的匹配结果 v_i^0 。

Step 4 输入聚类数目 c , 模糊因子 m , 和迭代终止条件, 聚类中心为 v_i^0 。

Step 5 用式 (3-4) 计算 u_{ij} 用式 (3-3) 计算, v_i^1 。

Step 6 如果 $\|v^1 - v^0\| \leq \delta$, 则迭代终止, 转步骤 7, 否则, 令 $v_i^0 = v_i^1 (i = 1, 2, \dots, c)$, 转向步骤 5。

Step 7 输出聚类结果 (V, U) , 确定聚类中心 $\mu_1(t), \mu_2(t), \dots, \mu_k(t)$ 。

Step 8 通过公式 (4-8) 计算训练样本的与聚类中心的距离 d_{ij} 。

$$d_{k,j} = \|X_j - \mu_k(t)\| \quad (4-7)$$

Step 9 根据公式 (4-9) 计算 RBF 神经网络隐含层神经元的扩展常数:

$$\sigma = kd_k \quad (4-8)$$

k 是重叠系数, d_k 是第 k 个数据中心和剩余的 $K-1$ 个数据中心之间的最小距离, 即

$$d_k = \min \|\mu_1 - \mu_k(t)\| \quad (4-9)$$

RBF 神经网络隐含层神经元的中心和扩展常数在通过 WWO-FCM 聚类算法确定之后, 采用最小二乘法 (LMS) 计算输出权值 $\omega = [\omega_1, \omega_2, \dots, \omega_k]^T$, 具体流程如下:

假设当输入样本 $X_j, j = 1, 2, \dots, N$ 时, RBF 神经网络隐含层输出矩阵为

$$H = \begin{bmatrix} \Phi_{11} & \Phi_{12} & \dots & \Phi_{1k} \\ \Phi_{21} & \Phi_{22} & \dots & \Phi_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \Phi_{j1} & \Phi_{j2} & \dots & \Phi_{jk} \end{bmatrix}_{N \times K} \quad (4-10)$$

其中, Φ_{jk} 为第 j 个样本输入时神经网络隐含层第 k 个神经元的输出值。

假设 RBF 神经网络的输出权值为 $\omega = [\omega_1, \omega_2, \dots, \omega_k]^T$ (待定), 则对所有样本的网络输出为

$$\hat{y} = H\omega \quad (4-11)$$

定义 RBF 神经网络拟合误差为

$$\varepsilon = \|y - \hat{y}\| = \|y - H\omega\| \quad (4-12)$$

则通过 LMS 求得 RBF 神经网络的输出权值为

$$\omega = H^+ y \quad (4-13)$$

其中, H^+ 为 H 的伪逆:

$$H^+ = (H^T H)^{-1} H^T \quad (4-14)$$

Step10 RBF 神经网络测试, 输出预测结果, 结束。

4.3 实验结果与分析

本实验采用标准 UCI 数据集中的 Auto MPG 数据集、Computer Hardware 数据集、winequality-white 数据集做实验, 实验环境与上一章完全相同。

Auto MPG 数据集 (汽车的燃油情况在不同的特征表现情况下的数据记录结果) 取自美国宾夕法尼亚大学的 StatLib 图书馆。在总数据集大小为 398 的数据集中选取 298 条作为训练集, 80 条作为测试集。图 4.2 为 Auto MPG 预测值与真实值的对比曲线图。图 4.3 为 Auto MPG 在三种模型下的预测误差对比曲线图。

Computer Hardware 数据集主要为针对 CPU 的性能特性做的数据记录结果共 209 条, 该数据包含 10 个属性。该数据集目标函数为 ERP 性能。训练集选取 181 条为, 测试集选取 28 条。图 4.4 为 Computer Hardware 预测值与真实值的对比曲线图。图 4.5 为 Computer Hardware 在三种模型下的预测误差对比曲线图。

winequality-white 数据集包含 4898 条葡萄酒的质量数据, 该数据一共有 12 个属性, 数据集的目标函数是质量, 专家根据客观输入 (葡萄酒专家进行的至少 3 次评估的中位数) 输出感官数据。每位专家对葡萄酒的质量进行了分级 0 (非常差) 到 10 (非常好) 之间。选择 3918 条作为训练集, 选择 980 条作为测试集。图 4.6 为 winequality-white 预测值与真实值的对比曲线图。图 4.7 为 winequality-white 在三种模型下的预测误差对比曲线图。




图 4.2 Auto MPG 预测值与真实值对比曲线

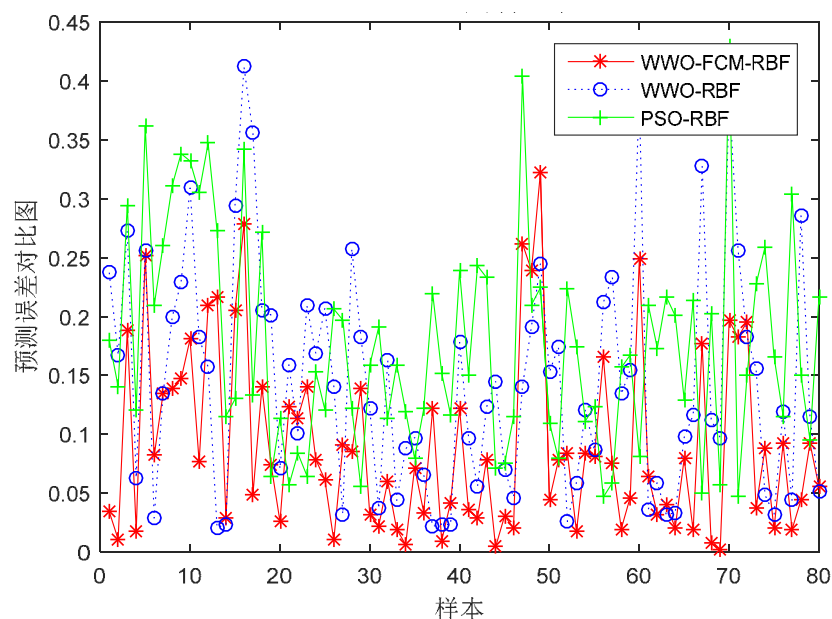


图 4.3 Auto MPG 在三种模型下的预测误差对比曲线

结果显示, 基于 Auto MPG 数据集的 WWO-RBF 模型和 PSO-RBF 模型预测误差平均值分别为 14.49%和 17.55%。而 WWO-FCM-RBF 模型的预测误差为 9.13%。略低于其他两个模型。因此, 本文构建的基于 WWO-FCM-RBF 的预测模型具有更高的预测准确率, 且性能更优。

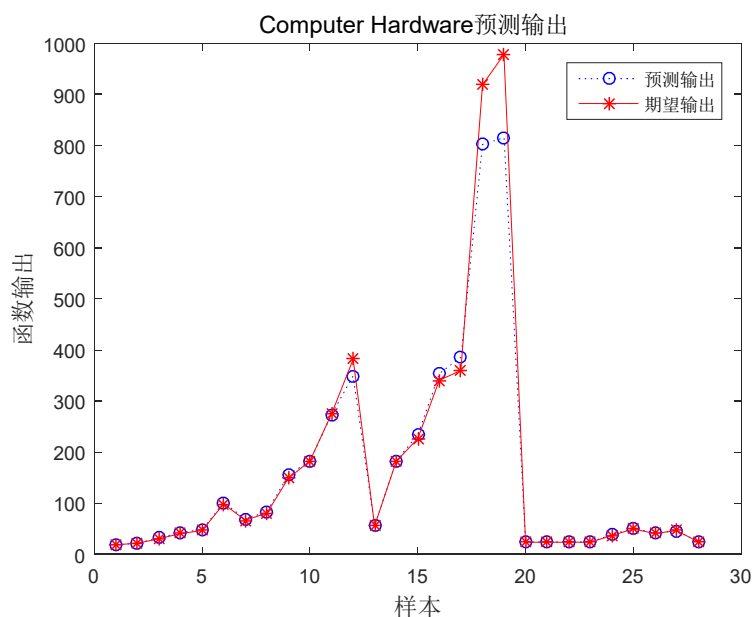


图 4.4 Computer Hardware 预测值与真实值对比曲线

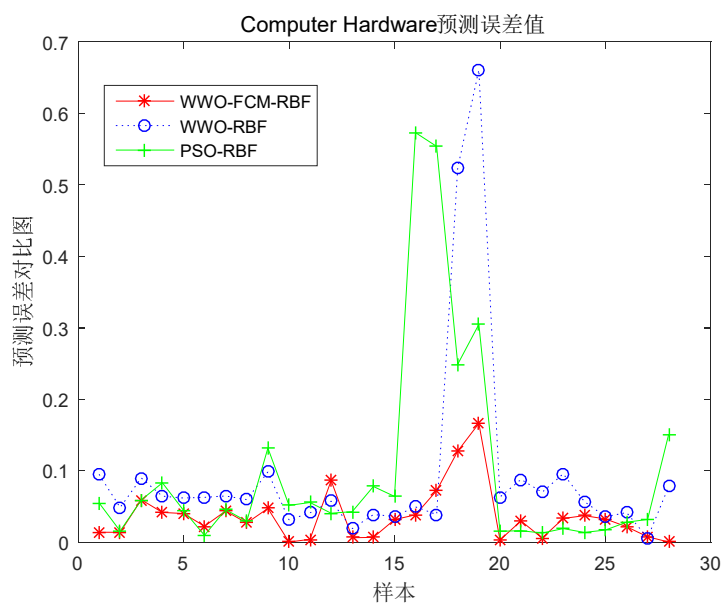


图 4.5 Computer Hardware 在三种模型下的预测误差对比曲线

结果显示，基于 Computer Hardware 数据集的 WWO-RBF 模型和 PSO-RBF 模型预测误差平均值分别为 9.542%和 9.951%。而 WWO-FCM-RBF 模型的预测误差为 3.67%。略低于其他两个模型。因此，本文构建的基于 WWO-FCM-RBF 的预测模型具有更高的预测准确率，且性能更优。

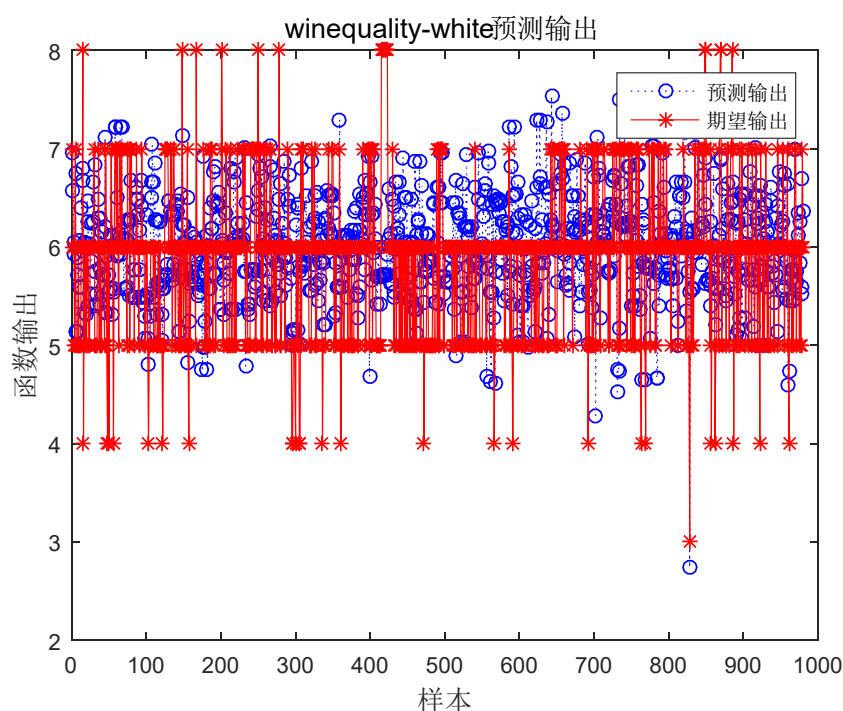


图 4.6 winequality-white 预测值与真实值的对比曲线

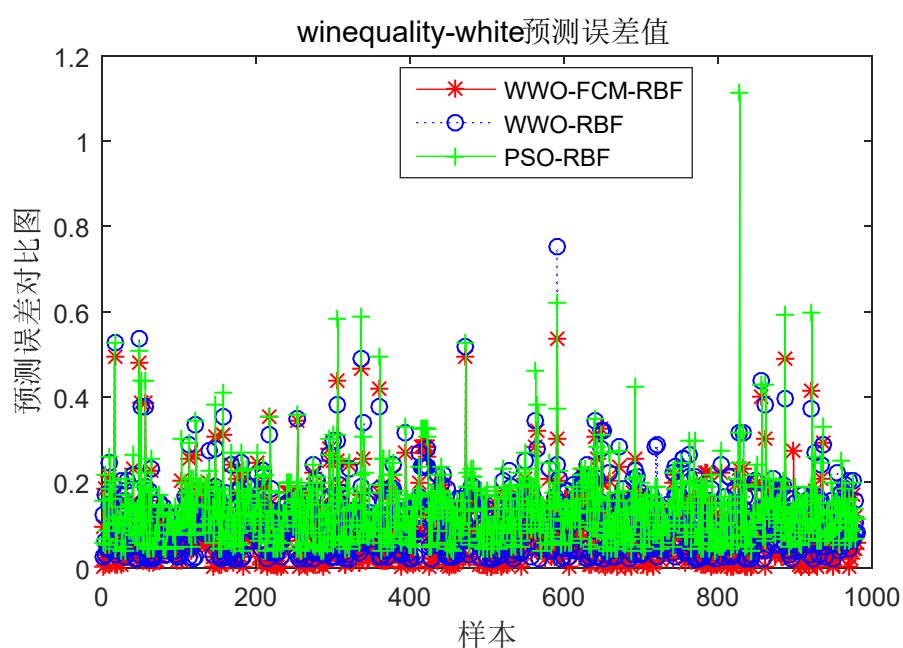


图 4.7 winequality-white 预测误差对比曲线

结果显示, 基于 winequality-white 数据集的 WWO-RBF 模型和 PSO-RBF 模型预测误差平均值分别为 11.13% 和 13.54%。而 WWO-FCM-RBF 模型的预测误差为 9.21%。略低于其他两个模型。所以本文构建的 WWO-FCM-RBF 预测模型预测准确率更高, 性能更优。

基于以上标准 UCI 真实数据集的分析验证实验, 说明本文构建的构建的

WWO-FCM-RBF 预测模型预测模型具有更高的预测准确率，因此，我们可以得出结论：算法是一种行之有效的可以对 RBF 神经网络预测精度进行有效改进的方法。

4.4 本章小结

本章针对 RBF 神经网络性能的影响因素做了分析，针对参数学习问题，设计出基于 WWO-FCM 优化改进的 RBF 神经网络学习方法。首先，对目前所能找到的 RBF 神经网络的基本架构进行剖析及必要的介绍，分析参数的变化情况对于 RBF 神经网络性能的具体影响情况。其次，在分析了参数优化方法对 RBF 神经网络的影响的基础上，选用 WWO-FCM 算法作为研究对象，对比 RBF 神经网络优化性能的结果数据来说明 WWO-FCM 算法具有更好的效果。最后列举了基于 WWO-FCM 改进的 RBF 神经算法的具体步骤及方法。通过 UCI 标准数据集对本模型理论进行预测，验证了模型的有效性和准确性。如将改进的模型应用于用电负荷预测，能使电量负荷预测精确度提高，预测速度加快，增强实用性和实效性。

第5章 基于水波算法改进神经网络的用电负荷预测

电力系统规划中重要的组成部分就是用电量负荷预测，同时，负荷预测也是电力系统经济运行的依据，其对重要性不言而喻。

电力负荷预测有两个含义，即指国家机关、企业、居民等用户安装的各种电气设备，它还可以描述上述受电设备消耗的电量值。

当电网执行在线控制时，准确的用电负荷预测可以满足供电量调度的需求。在最低成本情况下，效益最高，使电网良好有序运行。随着市场经济的快速发展，很多交易变成为线上交易，用电模式发生了很大改变，用电量也在不同的地区也呈现出不同的特点，因而耗电量值将直接影响电价的多少。随着用电负荷预测准确度增强使电力运营商更加高效地运营，获得显著收益。

5.1 电力负荷的影响因素分析

企业营运时，许多因素会影响电力负荷。主要因素包括时间因素、节假日因素以和气象因素，最高温度，最低温度，风向，风力强度和天气。发生的全球闻名的政治、经济事件或是其他随机因素等都会对影响负荷值。然而政治、经济活动及其他随机因素是随机因素，并未在一般模型中考虑，本模型选择的输入变量为确定性因素。

5.1.1 天气因素的影响

根据生活常识，在日常用电方面，在不同的季节，气温变化相对较大^[50]。季节气温对电量负荷预测有较大的影响^[51]。特别是夏季和冬季，雨雪天气多，空调和取暖设备大量使用，对负荷预测的性能要求更高，天气因素与电量存在很大的相关性。

5.1.2 节假日因素的影响

与通常负荷相比较，国家法定节假日(元旦、春节、五一、国庆)的负荷减少，商业负荷显著增加，工业负荷减少。同时，用电量的多少显示出与工作日和正常休息日不同的特性，但负荷通常会降低。假日电力显示出明显的规律。为保证节假日的正常供电，供电部门一般需要提前 15 至 20 天预测假期负荷，并向上级电

力部门报告，假期期间合理确定发电机的输出，因此对假期负荷预测是一件十分重要的工作。

5.2 数据处理方法

用电负荷预测是电力系统组成部分，是电能分配和输送的必要前提，因而准确预测用电量的多少十分必要。本论文采用阿里云天池数据平台上公布的江苏省扬中市高新区 1000 多家企业的历史用电量数据，详细记录了 2015 年 1 月 1 日至 2016 年 8 月 31 日的 1000 多家企业的每日用电量。并以此数据作为预测样本数据，精准预测下两个月的每日总用电量。

本文中使用的用户用电量多少的数据是收集的实际数据。在数据的收集、传输、存储等过程中，由于某些干扰，数据可能会丢失或异常。包括系统、设备发生故障、停电等特殊情况。未能处理这些数据将严重影响用电量能耗的准确度预测并限制负荷预测的准确性。从负荷预测的研究流程来看，负荷数据的预处理是研究的第一个步，也是十分关键的一步。

电力负荷量数据的观测值受到各种因素的影响，这些数据的存在对正确的建立模型影响大。是否能够有效地识别和校正异常负荷数据成为在建立负荷预测模型之前必须解决的问题。在本章中，通过分析负荷本身的规律性，对缺失数据进行补充。

用电量数据的归一化表明数据以适当方式归一化，使得数据的输入值在[0, 1]之间，这可以加速神经网络的收敛。数据的归一化公式如下 5-1。

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (5-1)$$

天气样本的处理：对阴天、晴天、下雨、下雪还有一些异常情况如台风，寒潮，冷空气，大雨，大雪，结冰进行数据处理，本节的输入层变量会包含天气这个模糊因素数据。在晴天，负荷变化比对稳定，但是阴天变化率较大，而雨天和下雪天变化则更加强烈。为了反映天气影响着负荷值，天气依次划分为晴天，多云天气，阴天，大雨，中雨，小雨，中雪和大雪。在特殊天气情况下，多云转中雨被视为中雨，晴转多云被视为按晴天。风向的处理方式为：东风，东北风，北风，西北风，西风，西南风，南风，东南风。风强的处理方式按照风力的等级划分处理，如果是 3-4 级风力则处理为 3.5。

日期类型处理：日期类型数据有两种形式，第一种是年月日，以一整年为一个周期归一化。第二种是星期，周一至周日分别标志为 1、2、3、4、5、6、7。遇到特殊放假日如国庆节端午节阅兵等标记为 8。如果周末调休变成工作日，标记 1。

5.3 实验结果与分析

本论文建立的工业电力负荷预测模型的验证分析基于 2015 年 1 月 1 日-2016 年 8 月 31 日江苏省扬中市 1000 多家企业的用电负荷值用作数据源。数据分成三部分，一部分作为训练集，其余作为测试集。采用 MATLAB 工具进行学习和预测。

针对以上数据的特征，该预测模型中每一个样本可以由一个 19 维向量组成，用 d1-d19 表示。每一维向量所表示的具体意义如表 5.1 所示。所以，本文设计的基于 WWO-FCM 的 RBF 神经网络模型的输入层包含 19 个神经元，在实验中，通过不断更新聚类中心和扩展常数，使得预测效果更好。

表 5.1 预测模型对应的维度及意义

维度	表示的意义
d1	归一化日期
d2	最高温度
d3	最低温度
d4	风向
d5	风强
d6	天气
d7	星期数
d8	节假日
d9-d18	前十天每天耗电量
d19	当天总耗电量

为了准确预测江苏省扬中市 2016 年 9、10 月份的用电负荷量，本文将 2015 年 1 月的每日负荷量数据和最高温度、最低温度、天气条件、风向、风力强度、假期等情况作为历史数据，8 个相关因素作为预测模块的输入，对 2016 年 9 月和 10 月负荷值作为输出。训练误差如图 5.1 所示。将预测结果与实际值进行比较，展示出本文提出的模型的准确性。如图 5.2 所示。




图 5.1 训练误差下降曲线

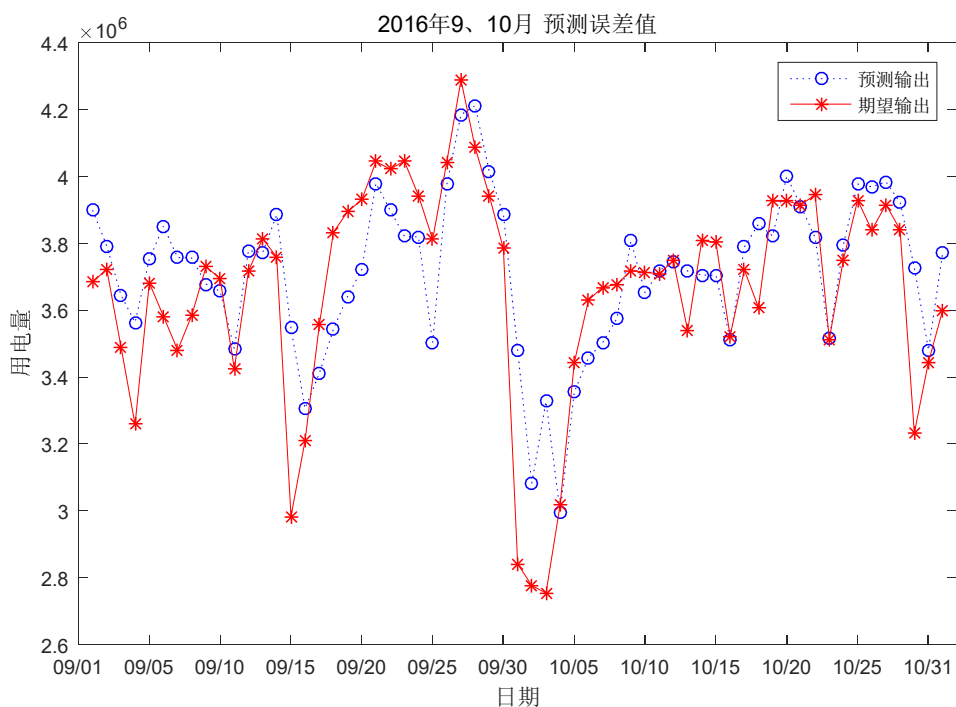


图 5.2 2016 年 9、10 月每日用电量预测值与真实值对比图

进一步分析本模型,分别用传统的 PSO-RBF 和 WWO-RBF 神经网络预测模型三种不同的预测模型同时进行实验验证,选取 2016 年 9 月和 10 月负荷预测量及误差值作为分析,三种模型的误差对比图如 5.3 所示。

设由模型输出的预测值为Pred, 实际值为True, 预测绝对误差值为:

$$E = |\text{Pred}_T - \text{True}_T| \quad (5-2)$$

预测相对误差ER为:

$$E_R = \frac{|Pred_T - True_T|}{True_T} \quad (5-3)$$

基于 WWO-FCM-RBF 神经网络电力预测方法变化平缓稳定, 误差变化范围在 2%至 23%之间, 平均误差为 4.33%。而 PSO-RBF 神经网络与 WWO-RBF 神经网络的误差为 5.6%和 6.64%且误差范围较大。所以本文提出的预测模型预测性能更优。

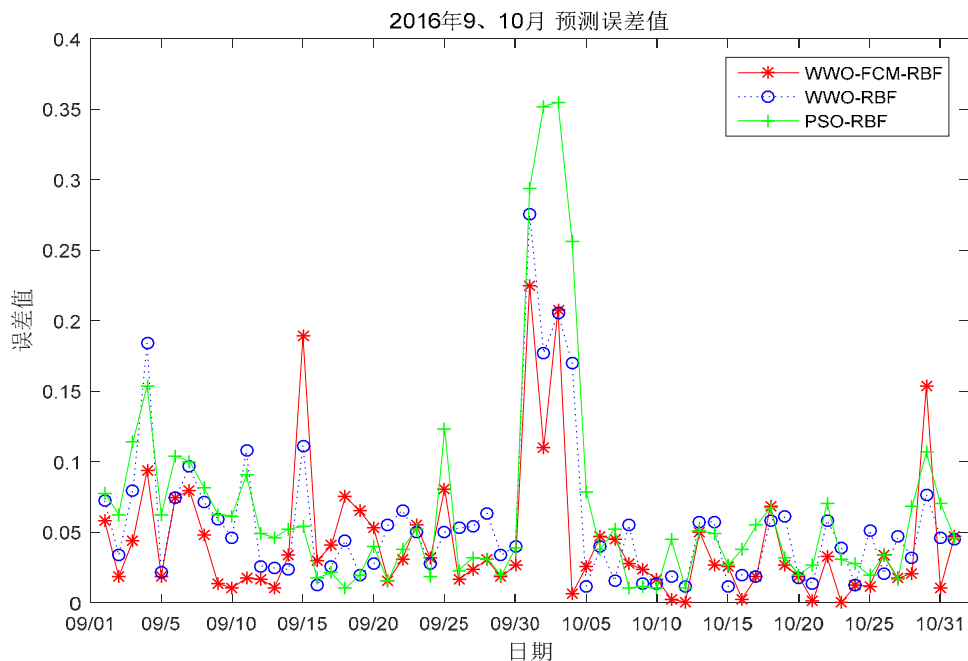


图 5.3 三种模型预测误差对比图

预测模型的优劣不仅取决于预测精度, 为了进一步测试本模型, 对本章模型训练时间进行计时, 并选取多次运行的平均值。速度对比如图 5.4 所示。




图 5.4 三种模型的速度对比图

由图 5.4 可以看出, 基于 WWO-FCM-RBF 神经网络电力负荷预测模型训练时长明显少于 PSO-RBF 和 WWO-RBF 模型。

由此可以得出, 本文设计的 WWO-FCM-RBF 神经网络电力负荷预测模型不仅更精确, 稳定性更强, 训练速度更快。

5.4 本章小结

本文获取了江苏省扬中市 2015 年 1 月至 2016 年 8 月的电力负荷数值, 并将归一化日期、最高温度、最低温度、风向、风力强度、天气变化、星期数, 假期情况等做了分析。建立了基于 WWO-FCM-RBF 神经网络的电力负荷预测模型, 对 2016 年 9 月和 10 月的用电量进行预测, 并选取这两个月的数据和其他传统模型进行比较。结果表明在同样训练集和验证集的情况下, WWO-FCM-RBF 神经网络的预测平均误差为 4.33%, 而 PSO-RBF 神经网络和 WWO-RBF 神经网络两种预测模型的误差为 5.6%和 6.64%, 说明本文提出的预测模型预测的更准确, 精度更高。同时本文提出的模型网络训练时间也是最短的。说明本文提出的 WWO-FCM-RBF 神经网络预测模型在保证预测精度的同时也保证了速度上的优势, 其预测能力能够满足工业用电规划和调度的需要, 其预测效果可靠、实用, 优于传统的优化预测模型, 可以广泛应用于实际电力系统的预测。

第6章 总结与展望

随着新一轮电力体制改革中对电力模式的重塑，在“两个替代、一个回归、一个提高”的战略体系中，电网是能量传输和转换利用的网络枢纽，是能源革命的核心。其中配网网架与用户用电体验密切相关，因此对电量负荷进行准确预测，实现配网能量流贯通，融合营销、生产等多源网架一体化，可以促进营配高效协同，提升配网规划设计、调度、运维和营销等各项核心业务的管理水平。

伴随着各行业用电负荷的逐步式增长，传统的电量预测方法存在着越来越多的缺陷，那么如何提高大规模用电环境下电量预测准确率以及性能，是电力系统研究的热点。

6.1 总结

本文基于目前研究很广、实用的神经网络模型，设计并实现了企业用电负荷预测模型，通过仿真实验更加准确地研究分析出了将神经网络模型应用于企业电力负荷预测的优势，并通过水波优化算法改进 FCM 模糊聚类，确定 RBF 神经网络的中心点和扩展常数的特点。本文的主要研究内容总结如下：

(1) 本文在研究 RBF 神经网络及其实现基于优化的 RBF 神经网络模型预测电力负荷之前，收集和整理了大量相关的国内外研究模型、算法、文献。总结出用电负荷预测的研究现状，在充分了解国内外对用电负荷预测的进展情况，根据 RBF 神经网络模型本身的特性，结合其缺陷，以及大量检索文献中神经网络算法在各个领域中的应用方式，研究和总结了将本文提出的优化模型可拓展的领域。

(2) 本文对实验研究中需要用到的相关知识、算法理论、算法过程进行了详细的描述和优缺点总结，其中，主要介绍了浅水波理论、水波优化算法、FCM 模糊聚类算法、RBF 神经网络算法的相关知识及特性。

(3) 本文进行了基于水波优化算法的模糊聚类算法模型的设计。并对其实现过程实现进行了详细的研究和阐述，设计出了水波优化算法改进模糊聚类的聚类中心的优化策略，实验过程中，选择 UCI 数据集进行实验研究。通过对比种群聚类的准确率和算法运行的时间以及适应函数的变化曲线，实验结果表明当种群规模一定时，基于水波优化算法改进模糊聚类算法的适应值明显 GA 算法和 PSO 算法，聚类准确率也得到了提升，运行时间也更少。

(4) 本文设计并实现了基于水波优化 RBF 神经网络隐含层神经元中心和扩

展常数等参数的方法，通过实验对改进的 RBF 神经网络在工业级用电负荷预测上的效果。将预测值与真实值相比，并对样本再次进行细分。选取前十天的预测结果分别与 PSO-RBF 和 WWO-RBF 预测结果相比，本文设计的预测模型误差为 5% 左右，而另外两种模型的准确率均为 6% 左右，可见其在预测精度上的优越性；同时与另外两种传统模型相比模型训练时间也更短，彰显了本文提出的优化模型在实际应用中的可靠性与实用性。

6.2 展望

RBF 神经网络同其他各类神经网络，如前馈神经网络（FF）、BP 神经网络、DFF 深度前馈神经网络、RNN 递归神经网络、LSTM 长短时记忆网络等一样，都是模拟生物神经的数学模型。所以此算法构建的网络参数及学习参数在一定程度上具有随机性，神经网络在学习的过程中也具有不可知性和不可控性，所以很难证明他的准确性与可靠性。

虽然在本文中设计实现的基于水波优化 RBF 神经网络的预测模型时，相较于传统模型在一定条件下在稳定性、寻优能力等方面表现的较好，但是本课题的研究仍有诸多的不足之处，所以在以后的研究中主要由以下几个方面进行改进：

（1）采用 RBF 神经网络模型，其学习和训练的过程复杂，学习算法很多，学习过程中参数的调整不具有确定性，因此选择合适的参数和算法，希望有更大更好地突破点。

（2）本文只针对用电负荷的几个重要因素做了分析和选择，但实际情况下影响负荷的因素远不止这些，需要与当地气象部门，商务部门，进出口等部门紧密联系，获得其他更重要的数据来源，以进一步提高预测精度。

参考文献

- [1] 章毅, 郭泉, 王建勇. 大数据分析的神经网络方法[J]. 工程科学与技术, 2017,49(1):9-18.
- [2] 杜忠明, 王雪松. “十三五”中国电力需求水平预测[J]. 中国电力, 2017(9):11-17.
- [3] 贾辛淼. 基于小波分析的电力系统短期负荷预测的应用研究[D]. 沈阳工业大学. 2016, 3.
- [4] 李琳. 基于 OpenStack 神经网络短省略荷预测模型在有序用电管理中的应用[J]. 智能电网, 2017,5(7):683-688.
- [5] 徐建军, 杜蕾楠, 闫丽梅. 基于对角递归神经网络的小区用电负荷预测研究[J]. 化工自动化及仪表, 2017,11(44):1052-1056.
- [6] Prediction of sea ice evolution in Liaodong Bay based on a back-propagation neural network model [J] Zhang, N (Zhang, Na) ; Ma, YT (Ma, Yuteng); Zhang, QH (Zhang, Qinghe) COLD REGIONS SCIENCE AND TECHNOLOGY. 65-75, 2017.10.02 出版年: JAN 2018.
- [7] Javed K , Babri H A , Saeed M . Feature Selection Based on Class-Dependent Densities for High-Dimensional Binary Data[J]. IEEE Transactions on Knowledge and Data Engineering, 2012, 24(3):465-477.
- [8] 杜蕾楠. 基于对角递归神经网络的智能小区用电负荷预测研究[D]. 东北石油大学. 2017, 5.
- [9] 朱雪雄. 基于人工神经网络的短期居民用电负荷预测研究[J]. 科技创新与应用, 2017(23):20-20.
- [10] 卢继哲. 基于智能用电信息采集系统的负荷特性分析及预测[D]. 华北电力大学, 2017.3.
- [11] 苏适, 周立栋, 万筱钟, 陆海, 严玉廷, 王飞. 计及气象因素的用电负荷短期分时分类预测模型与方法[J]. 电力建设, 2017,38(10):76-83.
- [12] Hagan M T, Behr S M. The Time Series Approach to Short Term Load Forecasting[J]. Power Systems IEEE Transactions on, 1987, 2(3):785 -791.
- [13] D.C. Park, M. A. El-Sharkawi, R. J. Marks, L. E. Atlas and M. J. Damborg, Electric load forecasting using an artificial neural network, [J] in IEEE Transactions on Power Systems, vol. 6, no. 2: 442-449, May 1991.
- [14] Chaturvedi D K, Sinha A P, Malik O P. Short term load forecast using fuzzy logic and wavelet transform integrated generalized neural network[J]. International Journal of Electrical Power & Energy Systems, 2015, 67:230 -237.
- [15] Lusi P, Khalilpour K R, Andrew L, et al. Short-term residential load forecasting: Impact of calendar effects and forecast granularity[J]. Applied Energy, 2017, 205:654-669.
- [16] Barman M, Choudhury N B D, Sutradhar S. A regional hybrid GOA-SVM model based on similar day approach for short-term load forecasting in Assam[J]. Energy, 2018.
- [17] Haben S, Singleton C, Grindrod P. Analysis and clustering of residential customers energy behavioral demand using smart meter data[J]. IEEE transactions on smart grid, 2016, 7 (1): 136-144.
- [18] 李栓, 刘莉, 刘阳. 趋势外推法在电力负荷预测中的应用[J]. 沈阳工程学院学报(自然科学

版), 2005,1(2):64-65.

- [19] 程超. 基于时间序列法和回归分析法的改进月售电量预测方法研究[D].重庆大学,2016.
- [20] 梁唐杰. 电力负荷预测方法研究及其应用[J]. 通讯世界, 2018, No.334(03):244-246.
- [21] 蒋浩然, 刘小聪, 李扬. 基于多变量灰色预测模型的省级电力公司中长期电量预测[J]. 电力需求侧管理, 2019(1):37-41.
- [22] 徐文权, 胡慧, 卓张华, et al. RBF-AR 模型在三峡水电站上网日电量预测中的应用[J]. 淮海大学学报(自然科学版), 2018, v.46(03): 90-97.
- [23] 方志强, 王晓辉, 夏通. 基于长短期记忆网络的售电量预测模型研究[J]. 电力工程技术, 2018, v.37,No.179(03):84-89.
- [24] 胡时雨, 罗滇生, 阳霜, et al. 基于多变量 LS-SVM 和模糊循环推理系统的负荷预测[J]. 计算机应用, 2015, 35(2):595-600.
- [25] Zheng Y J. Water wave optimization: A new nature-inspired metaheuristic[J]. Computers & Operations Research, 2015, 55:1-11.
- [26] 吴秀丽, 周永权. 一种基于混沌和单纯形法的水波优化算法[J]. 计算机科学, 2017, 44(5):218-225.
- [27] 张蓓, 郑宇军. 水波优化算法收敛性分析[J]. 计算机科学, 2016, 43(4):41-44.
- [28] 郑宇军, 张蓓, 薛锦云. 软件形式化开发关键部件选取的水波优化方法[J]. 软件学报, 2016, 27(4):933-942.
- [29] 张杰峰, 郑宇军. 种群规模可变的水波优化算法[J]. 南京大学学报, 2015, 51(4):850-857.
- [30] Shao Z, Pi D, Shao W. A novel discrete water wave optimization algorithm for blocking flow-shop scheduling problem with sequence-dependent setup times[J]. Swarm & Evolutionary Computation, 2017.
- [31] Zhao F, Liu H, Zhang Y, et al. A Discrete Water Wave Optimization Algorithm for No-wait Flow Shop Scheduling Problem[J]. Expert Systems with Applications, 2017, 91.
- [32] Zhao S, Li Z, Yun X, et al. IIR filters designing by water wave optimization[C]// IEEE International Conference on Control & Automation. IEEE, 201:347-352.
- [33] Wu X, Zhou Y, Lu Y. Elite Opposition-Based Water Wave Optimization Algorithm for Global Optimization[J]. Mathematical Problems in Engineering, 2017, (2017-01-15), 2017:1-25.
- [34] Wu X B, Liao J, Wang Z C. Water Wave Optimization for the Traveling Salesman Problem[C]// International Conference on Intelligent Computing. Springer, Cham, 2015:137-146.
- [35] Sheshaaayee A, Sridevi D. A Combined System for Regionalization in Spatial Data Mining Based on Fuzzy C-Means Algorithm with Gravitational Search Algorithm[J]. 2017, pp787-794.
- [36] Ren Z, Wang C, et al. Fuzzy clustering based on Water Wave Optimization[C] // International Conference on Computer Science & Education. ICCSE, 2018:85-89.
- [37] Raveen S, Prasad P S S, Chillarige R R. A New Preprocessor to Fuzzy c-Means Algorithm[C]// International Workshop on Multi-Disciplinary Trends in Artificial Intelligence. Springer-Verlag New York, Inc. 2014, 5:124-135.
- [38] Rubio E, Castillo O, Melin P. Interval Type-2 Fuzzy System Design Based on the Interval Type-2 Fuzzy C-Means Algorithm[J]. 2016.
- [39] Pang L, Xiao K, Liang A, et al. A Improved Clustering Analysis Method Based on Fuzzy

- C-Means Algorithm by Adding PSO Algorithm[M]// Hybrid Artificial Intelligent Systems. Springer Berlin Heidelberg, 2012:231-242.Zhang B, Xue L, Wang W, et al. An Improving Fuzzy C-means Algorithm for Concept-Drifting Data Stream[J]. 2016: 439-450.
- [40] Garai P, Maji P. Identification of Co-Expressed microRNAs Using Rough Hypercuboid Based Interval Type-2 Fuzzy C-Means Algorithm[C]// International Conference on Advanced Computing and Intelligent Engineering. 2016.
- [41] Tripathy B K, Tripathy A, Govindarajulu K, et al. On Kernel Based Rough Intuitionistic Fuzzy C-means Algorithm and a Comparative Analysis[J]. 2014, 2014(27) :349-359.
- [42] Li M, Song Y C, Li Y, et al. Research of improved fuzzy c -means algorithm based on a new metric norm[J]. Journal of Shanghai Jiaotong University, 2015, 20(1):51-55.
- [43] Kuo H C, Lin Y J. The Optimal Estimation of Fuzziness Parameter in Fuzzy C-Means Algorithm[M]// Rough Sets. 2017, 2017(10313):51–55.
- [44] Szilágyi L, Szilágyi S M, Enăchescu C. A Study on Cluster Size Sensitivity of Fuzzy c -Means Algorithm Variants[M]// Neural Information Processing. Springer International Publishing, 2016, 2016(9948) :470-478.
- [45] Agrawal S, Tripathy B K. Decision Theoretic Rough Intuitionistic Fuzzy C-Means Algorithm[J]. 2016, 2016(50) :71-82.
- [46] Endo Y, Kinoshita N, Iwakura K, et al. Hard and Fuzzy c-means Algorithms with Pairwise Constraints by Non-metric Terms[J]. 2014, 8825:145-157.
- [47] Kumar S, Kashyap M, Saluja A, et al. Segmentation of Cotton Bolls by Efficient Feature Selection Using Conventional Fuzzy C-Means Algorithm with Perception of Color[J]. 2016, 2016 (239):731-741.
- [48] Hassen D B, Taleb H, Yaacoub I B, et al. Classification of Chest Lesions with Using Fuzzy C-Means Algorithm and Support Vector Machines[M]// International Joint Conference SOCO'13-CISIS'13-ICEUTE'13. Springer International Publishing, 2014:319-328.
- [49] 乔杉. 基于神经网络的人脸识别方法研究 [D]. 中国地质大学（北京），2014.
- [50] 啜斌. 计及雾霾影响的保定电网典型负荷短期预测研究[D]. 华北电力大学，2016.
- [51] 谢文娟，牛帅. 焦作市气象因素与用电负荷的关系及预测模型的研究[J]. 河南电力应用,2016(2):51-52.

致谢

时光转瞬即逝，本人的硕士研究生学习阶段，已经快要结束了。说起来有着太多的不舍与怀念。三年的时光看似漫长，却又是那么的短暂，有辛酸、迷惘，但更多的是历练和收获，我们都在快乐的眼泪中成长着。这三年以来，我始终觉得自己特别幸运，因为我有认真负责的老师，互帮互助的同学们，有着丰富经验的师兄师姐们，团结可爱的师弟师妹们。是你们陪我一同度过这一段志同道合、丰富多彩的学习时光。我时时刻刻感受到了来自你们的正能量，你们积极向上的态度感染着我，优良的学风指引着我。正是在智慧网络和信息处理实验室这种端正的学风环境下，不断激励着我学习新知识，克服新困难。也正是有了你们的帮助，我才能在学习的道路上不断前行，在正确的指导下，我不断解决学习疑惑，在不断地积累下，我才能顺利完成学业。

首先，我要感谢的是我的导师王春枝教授，她不仅在学术上给我指引方向，督促我按时按量完成学业任务，达到毕业要求；还教会我如何与人为善，宽厚待人；鼓励我勇于尝试，树立信心；这必将使我受用一生。我的学位论文是在我的恩师王春枝教授和叶志伟教授指导下完成的，我由衷的感谢你们对我一直以来的耐心引导，包容有序，协调推进。从培养方案的制定、课程的学习、研究方向的选择、课题的确立、研究路线的实施，论文的研究成型，王教授和叶教授都始终给我诚恳的建议和坚实的支持，我取得的每一份成就都凝聚着你们不辞辛劳的付出，充满着汗水与热情。两位导师严谨的学术态度、深厚的知识储备、兢兢业业的工作热情，敦促着我，令我时刻谨记在工作上不断发光发热的人生姿态。在此谨向王教授和叶教授致以感谢！

感谢赐予我与同在实验室大家庭下学习的兄弟姐妹的这一份缘分！感谢你们让我快乐的享受这这一段快乐的时光！在此我要对实验室的同学，师兄师姐，学弟学妹们在学习和工作中给与我的帮助，表示最真诚的谢意。感谢和我一起参加比赛的伙伴陈颖哲、王毅超等，感谢在实验过程给我提供新思路的方策、蔡文成、陈凤等和论文写作时给我建议的陈文倩、杨娟等。无论我遇到什么困难，不管我们是不是一个研究方向，他们都不辞辛劳，与我一同研究探讨。

最后，感谢我的家人给我坚强的力量，感谢评审老师辛苦评审我的论文，感谢答辩专家对我的检验！

附录

攻读硕士学位期间取得的学术成果

- [1] Ren Z, Wang C, Ye Z, et al. Fuzzy clustering based on Water Wave Optimization[C] // International Conference on Computer Science & Education. ICCSE 2018: pp.85-89. (EI 收录)
- [2] 申请国家发明专利 《BP 神经网络权值确定方法、系统以及预测方法、系统》-公开号 CN108288093A
- [3] 参与科研项目 国家自然科学基金 基于深度学习的非结构化大数据分析算法研究 (基金号: 6177051856)